

**KLASIFIKASI KELAYAKAN PENERIMA SUBSIDI LISTRIK
RUMAH TANGGA PELANGGAN PLN ACEH
MENGUNAKAN METODE *LIGHT GRADIENT BOOSTING
MACHINE* (LIGHTGBM)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk
Menyelesaikan Pendidikan Jenjang Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

SITI NUR FAIZA

NIM	: 2022573010045
Program Studi	: Teknik Informatika
Jurusan	: Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE
TAHUN 2026**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul “*Klasifikasi Kelayakan Penerima Subsidi Listrik Rumah Tangga Pelanggan PLN Aceh Menggunakan Metode Light Gradient Boosting Machine (LightGBM)*”, disusun oleh Siti Nur Faiza, NIM 2022573010045, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan di hadapan dewan penguji.

.
Pembimbing I

Buketrata, 22 Juli 2026
Pembimbing II

Salahuddin, S.T., M.CS

Hendrawaty, ST., M.T.

NIP. 19740424 200212 1 001

NIP. 19700226199802 2 001

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan
Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.CS

M. Khadafi, S.T., M.T

NIP. 19740424 200212 1 001

NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul “*Klasifikasi Kelayakan Penerima Subsidi Listrik Rumah Tangga Pelanggan PLN Aceh Menggunakan Metode Light Gradient Boosting Machine (LightGBM)*”, disusun oleh Siti Nur Faiza, NIM 2022573010045, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan di hadapan dewan penguji dan dinyatakan lulus pada tanggal 22 Juli 2026.

Komisi Sidang,

Salahuddin, S. T., M.CS (Ketua Sidang)
NIP. 1974024 200212 1 001

Hendrawaty, ST., M.T. (Sekretaris Sidang)
NIP. 19700226199802 2 001

Musta'inul Abdi, S.S.T., M.Kom. (Penguji I)
NIP. 19911030 201903 1 015

Radhiyatammardhiyyah, S.S.T., M.Sc. (Penguji II)
NIP. 19920826 202203 2 011

Dr. Rahmad Hidayat, S.Kom., M.Cs. (Penguji III)
NIP. 19830420 201212 1 003

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan
Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S. T., M.CS
NIP. 1974024 200212 1 001

Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Buketrata, 22 Juli 2026

Siti Nur Faiza
NIM. 2022573010045

KATA PENGANTAR

Puji syukur penulis panjatkan kehadiran Allah SWT, karena atas rahmat and hidayah-Nya, penulis dapat menyelesaikan skripsi ini dengan judul *Klasifikasi Kelayakan Penerima Subsidi Listrik Rumah Tangga Pelanggan PLN Aceh Menggunakan Metode Light Gradient Boosting Machine (LightGBM)*. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Terapan pada Program Studi Teknik Informatika Politeknik Negeri Lhokseumawe. Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang bersifat membangun dari semua pihak. Dalam penulisan Skripsi ini penulis dapat melaksanakannya dengan baik berkat dukungan, bimbingan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Allah SWT atas segala rahmat, nikmat, kesehatan, serta kekuatan yang diberikan kepada penulis sehingga dapat menyelesaikan skripsi ini.
2. Keluarga tercinta yang selalu memberikan doa, dukungan moral maupun material, serta motivasi kepada penulis selama proses penyelesaian pendidikan.
3. Bapak Dr. Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM, ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negeri Lhokseumawe.
4. Bapak Salahuddin, S.T., M.CS selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T. selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Salahuddin, S.T., M.CS selaku Pembimbing Utama dan Ibu Hendrawaty, ST., M.T selaku Pembimbing Pendamping yang telah membantu, membimbing, dan mengarahkan penulis dalam proses penyelesaian Skripsi ini.
6. Bapak Musta'inul Abdi, S.S.T., M.Kom., Bapak Dr. Rahmad Hidayat, S.Kom., M.Cs., and Ibu Radhiyatammardhiyyah, S.S.T., M.Sc. selaku penguji yang telah bersedia memberikan arahan dan masukan dalam pengerjaan Skripsi ini.
7. Seluruh Dosen Pengajar Program Studi Teknik Informatika yang telah memberikan ilmu dan motivasi kepada penulis selama masa perkuliahan.

Penulis menyadari bahwa Skripsi ini masih terdapat kekurangan dan ketidaksempurnaan. Oleh sebab itu, penulis mengharapkan adanya saran dan kritik yang membangun guna dijadikan bahan perbaikan dan pembelajaran untuk ke depannya yang bermanfaat bagi penulis dan rekan-rekan yang membacanya. Semoga bantuan dan kebaikan semua pihak dapat menjadi amal ibadah.

Buketrata, 22 Juli 2026

Siti Nur Faiza
NIM. 2022573010045

ABSTRAK

Subsidi listrik merupakan bantuan pemerintah yang diberikan kepada masyarakat yang memenuhi kriteria tertentu untuk meringankan biaya penggunaan energi listrik. Meskipun demikian, proses penentuan kelayakan penerima subsidi listrik masih memerlukan mekanisme yang lebih akurat dan objektif sehingga diperlukan pendekatan berbasis data untuk membantu pengambilan keputusan. Salah satu pendekatan yang dapat digunakan adalah teknik machine learning melalui metode klasifikasi. Penelitian ini bertujuan membangun model klasifikasi kelayakan penerima subsidi listrik pelanggan rumah tangga di wilayah PLN Aceh menggunakan metode Light Gradient Boosting Machine (LightGBM). Data yang digunakan terdiri atas ID pelanggan, nama pelanggan, daya listrik (VA), golongan tarif, konsumsi listrik per bulan (kWh), penghasilan, jumlah anggota keluarga, pekerjaan kepala keluarga, status kepemilikan rumah, luas bangunan, dan status penerima bantuan, dengan output berupa klasifikasi layak atau tidak layak menerima subsidi listrik. Data diproses melalui tahapan preprocessing, pembagian data training dan testing, pelatihan model, serta evaluasi menggunakan metrik accuracy, precision, recall, dan F1-score. Hasil penelitian diharapkan menghasilkan model dengan tingkat akurasi yang baik dalam mengklasifikasikan kelayakan penerima subsidi listrik sehingga dapat mendukung PLN dalam proses pengambilan keputusan secara lebih efektif dan objektif.

Kata Kunci: Klasifikasi, Subsidi Listrik, Light Gradient Boosting Machine (LightGBM)

ABSTRACT

Electricity subsidy is government assistance provided to communities that meet certain criteria to reduce the cost of electricity consumption. Nevertheless, the process of determining the eligibility of electricity subsidy recipients still requires a more accurate and objective mechanism, hence a data-driven approach is needed to assist in decision-making. One approach that can be used is machine learning techniques through classification methods. This study aims to build a classification model for the eligibility of household electricity subsidy recipients in the PLN Aceh region using the Light Gradient Boosting Machine (LightGBM) method. The data used consists of customer ID, customer name, electrical power (VA), tariff category, monthly electricity consumption (kWh), income, number of family members, head of family occupation, house ownership status, building area, and assistance recipient status, with the output being the classification of eligible or ineligible to receive electricity subsidy. The data is processed through the stages of preprocessing, dividing training and testing data, model training, and evaluation using accuracy, precision, recall, and F1-score metrics. The results of the study are expected to produce a model with a good level of accuracy in classifying the eligibility of electricity subsidy recipients so that it can support PLN in a more effective and objective decision-making process.

Keywords: *Classification, Electricity Subsidy, Light Gradient Boosting Machine (LightGBM)*

DAFTAR ISI

PENGESAHAN PEMBIMBING	ii
PENGESAHAN PENGUJI	iii
HALAMAN PERNYATAAN.....	iv
KATA PENGANTAR	v
ABSTRAK	vii
ABSTRACT.....	viii
DAFTAR ISI	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiv
BAB I PENDAHULUAN	2
1.1 Latar Belakang	2
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Batasan Masalah.....	5
1.5 Manfaat Penelitian	6
BAB II TINJAUAN PUSTAKA	7
2.1 State of the Art	7
2.2 Tinjauan Teoritis.....	11
2.2.1 Klasifikasi Dalam Machine Learning	11
2.2.2 Supervised Learning dan Unsupervised Learning.....	12
2.2.3 Subsidi Listrik di Indonesia	13
2.2.4 PT. PLN (Persero) Unit Induk Distribusi Aceh.....	15
2.2.5 Model Boosting dalam Machine Learning	15
2.2.6 Light Gradient Boosting Machine	16
BAB III METODOLOGI PENELITIAN	22
3.1 Data dan Pengumpulan Data.....	22
3.1.1 Tempat Penelitian	22
3.1.2 Waktu Penelitian	23
3.1.3 Alat dan Bahan.....	24
3.1.4 Variabel Data	26
3.1.5 Sumber Data	27
3.1.5.1 Ekstraksi dan Agregasi Data (Format CSV).....	31
3.1.6 Analisis Kebutuhan Data	33
3.1.7 Preprocessing Data	35

3.2	Rancangan Sistem	36
3.2.1	Metode Penelitian	36
3.2.1.1	Alur Penelitian	37
3.2.2	Diagram Use Case	40
3.2.3	Arsitektur Sistem	43
3.2.4	Class Diagram.....	47
3.2.5	Activity Diagram.....	48
3.2.6	<i>Entity Relationship Diagram</i> (ERD)	52
3.2.7	Rancangan Algoritma <i>Long Short-Term Memory</i> (LSTM) .	55
3.2.8	Perancangan <i>Wireframe</i>	62
3.2.9	Teknik Pengujian	68
3.2.9.1	Rancangan Pengujian Evaluasi Model Prediksi	69
3.2.9.2	Rancangan Analisis Pengujian <i>Black Box</i>	70
3.2.9.3	Rancangan Analisis Pengujian <i>White Box</i>	72
3.2.10	Indikator Keberhasilan Penelitian	73
BAB IV	HASIL DAN PEMBAHASAN	75
4.1	Hasil Implementasi Sistem	76
4.1.1	Implementasi Antarmuka (UI)	76
4.1.2	Implementasi Backend dan Basis Data Cloud	85
4.1.3	Implementasi Layanan Prediksi (API)	86
4.2	Preprocessing Data	90
4.2.1	Deskripsi Data dan Eksplorasi Awal	90
4.2.2	Pra-pemrosesan dan Pembentukan Sequence	91
4.3	Implementasi dan Pelatihan Model Prediksi	93
4.3.1	Arsitektur Model dan Skenario Eksperimen	94
4.3.2	Hasil Pelatihan Model	95
4.3.3	Implementasi Augmentasi Data Sintetis TimeGAN	97
4.3.4	Implementasi Prediksi Rekursif ke Depan	99
4.4	Evaluasi Model	102
4.4.1	Evaluasi Model dan Perbandingan dengan Baseline	103
4.4.2	Evaluasi Multi-Seed dan Analisis Kestabilan	105
4.4.3	Evaluasi Augmentasi Data Sintetis TimeGAN	108
4.5	Hasil Pengujian Sistem	110
4.5.1	Skenario Pengujian	110
4.5.2	Hasil Black Box Testing	111
4.5.3	Hasil White Box Testing	113
4.5.4	Evaluasi Kinerja Model	116

4.6	Pembahasan.....	116
4.6.1	Pembahasan Pengujian Fungsional dan Arsitektur Offline- First	116
4.6.2	Pembahasan Hasil Prediksi Penjualan LSTM	117
4.7	Keterbatasan Sistem dan Penelitian	120
4.7.1	Keterbatasan Sistem POS.....	120
4.7.2	Keterbatasan Penelitian Model Prediksi	121
BAB V	PENUTUP.....	124
5.1	Kesimpulan	124
5.2	Saran	126
	DAFTAR PUSTAKA.....	129
	LAMPIRAN	132

DAFTAR GAMBAR

2.1	Metode Light Gradient Boosting Machine	18
3.1	Alur Penelitian	38
3.2	<i>Use Case Diagram</i> Sistem POS	41
3.3	Arsitektur Sistem POS	44
3.4	Class Diagram Sistem POS	47
3.5	Activity Diagram Alur Kerja Transaksi Kasir	49
3.6	Activity Diagram Sinkronisasi Latar Belakang.....	50
3.7	Activity Diagram Proses AI Smart Analytics	51
3.8	Activity Diagram Kelola Produk (Tambah/Ubah/Hapus)	52
3.9	<i>Entity Relationship Diagram</i> (ERD) Sistem POS	53
3.10	Alur Kerja Algoritma <i>Long Short-Term Memory</i> (LSTM).....	55
3.11	<i>Wireframe</i> Halaman Registrasi Toko Baru.....	62
3.12	<i>Wireframe</i> Halaman <i>Login</i>	63
3.13	<i>Wireframe</i> Halaman Pemilihan Toko.....	63
3.14	<i>Wireframe</i> Halaman Dasbor Owner	64
3.15	<i>Wireframe</i> Halaman POS (Pembayaran).....	64
3.16	<i>Wireframe</i> Halaman Riwayat Transaksi	65
3.17	<i>Wireframe</i> Halaman Kelola Produk	65
3.18	<i>Wireframe</i> Halaman Kelola Kategori	66
3.19	<i>Wireframe</i> Halaman Laporan	66
3.20	<i>Wireframe</i> Halaman Pengaturan.....	67
3.21	<i>Wireframe</i> Halaman Informasi Toko	67
3.22	<i>Wireframe</i> Halaman Struk Digital	68
3.23	<i>Wireframe</i> Halaman Katalog Produk.....	68
4.1	Implementasi Halaman Registrasi	77
4.2	Implementasi Halaman <i>Login</i>	77
4.3	Implementasi Halaman Informasi Toko	78
4.4	Implementasi Halaman Pilih Toko	78
4.5	Implementasi Halaman Dasbor Owner	79
4.6	Implementasi Halaman Kelola Produk dan Tambah Produk.....	79
4.7	Implementasi Halaman Kelola Kategori	80
4.8	Implementasi Halaman Kelola Stok dan Ubah Stok Produk.....	80
4.9	Implementasi Halaman Riwayat Stok.....	81
4.10	Implementasi Halaman Kasir (POS) dan Detail Pesanan	81

4.11 Implementasi Halaman Pembayaran	82
4.12 Implementasi Halaman Riwayat Transaksi	82
4.13 Implementasi Halaman Struk Digital	83
4.14 Implementasi Halaman Laporan Analitik.....	84
4.15 Implementasi Halaman <i>Smart Analitik</i>	85
4.16 Implementasi Halaman Riwayat Analisis.....	85
4.17 Kurva Kerugian Pelatihan (<i>Training Loss Curve</i>) Model LSTM	97
4.18 Grafik Pendapatan Aktual vs. Prediksi Model LSTM Hybrid	105
4.19 Boxplot Distribusi MAE Hasil Pengujian <i>Multi-Seed</i>	108

DAFTAR TABEL

3.1	Jadwal Pelaksanaan Penelitian	24
3.2	Daftar Alat dan Bahan Penelitian	24
3.3	Sebaran Penjualan Berdasarkan Kategori Produk	29
3.4	Daftar 10 Produk Terlaris EatsTEDI UGM	30
3.5	Struktur Skema Dataset <i>daily_sales.csv</i>	32
3.6	Struktur Skema Dataset <i>weekly_sales.csv</i>	33
3.7	Struktur Skema Dataset <i>monthly_sales.csv</i>	33
3.8	Definisi Aktor	42
3.9	Definisi <i>Use Case</i>	42
3.10	Daftar Tabel Basis Data POS	54
3.11	Skenario Pengujian <i>Black Box</i>	70
4.1	Statistik Ringkas Dataset Pendapatan Harian	90
4.2	Pembagian Dataset dan Dimensi Sequence	92
4.3	Perbandingan Performa pada Data Uji (<i>One-Step-Ahead</i>)	103
4.4	Statistik Performa LSTM Hybrid pada 10 Seed	107
4.5	Perbandingan Performa Eksperimen Augmentasi TimeGAN (<i>Multi-Step</i> , Horizon 7)	109
4.6	Hasil Pengujian Black Box	111
4.7	Hasil Pengujian Mekanisme Sinkronisasi	113
4.8	Hasil Pengujian White Box	115

BAB I

PENDAHULUAN

1.1 Latar Belakang

Subsidi listrik merupakan salah satu bentuk kebijakan strategis pemerintah dalam menjamin pemerataan akses energi serta meningkatkan kesejahteraan masyarakat berpenghasilan rendah [1]. Energi listrik telah menjadi kebutuhan dasar dalam kehidupan modern karena hampir seluruh aktivitas rumah tangga, pendidikan, ekonomi, dan layanan publik bergantung pada ketersediaan listrik yang stabil dan terjangkau [2]. Oleh karena itu, pemerintah melalui PT PLN (Persero) sebagai perusahaan penyedia tenaga listrik nasional, menyalurkan subsidi listrik khususnya kepada pelanggan rumah tangga dengan daya rendah seperti 450 VA dan 900 VA. Kebijakan ini bertujuan untuk meringankan beban pengeluaran masyarakat kurang mampu serta mendukung peningkatan taraf hidup secara berkelanjutan [3].

Berdasarkan evaluasi kebijakan subsidi energi dan laporan kinerja sektor ketenagalistrikan, masih terdapat pelanggan yang secara ekonomi tergolong mampu tetapi tetap menerima subsidi, sementara sebagian masyarakat yang lebih membutuhkan justru belum terdata atau belum terjangkau program bantuan. Permasalahan ini umumnya disebabkan oleh pendekatan penentuan penerima subsidi yang masih bertumpu pada indikator administratif sederhana, seperti daya listrik terpasang dan golongan tarif, tanpa mempertimbangkan secara komprehensif pola konsumsi listrik, riwayat pembayaran, serta karakteristik sosial

ekonomi pelanggan. Kondisi tersebut menunjukkan bahwa proses identifikasi penerima subsidi masih memerlukan sistem pendukung keputusan yang lebih objektif, terukur, dan berbasis data [4]. Perkembangan teknologi informasi dan meningkatnya ketersediaan data pelanggan listrik membuka peluang besar untuk menerapkan pendekatan analisis data dalam mendukung kebijakan subsidi [5]. Data administratif pelanggan, data konsumsi energi listrik, serta riwayat pembayaran yang dikelola oleh PT PLN (Persero), khususnya di wilayah Unit Induk Distribusi Aceh, memiliki potensi untuk dianalisis lebih lanjut guna menemukan pola yang mencerminkan kondisi kelayakan penerima subsidi. Pemanfaatan teknik machine learning dalam pengolahan data memungkinkan sistem untuk mempelajari hubungan kompleks antar variabel secara otomatis, sehingga proses klasifikasi dapat dilakukan secara lebih akurat dibandingkan metode manual atau berbasis aturan sederhana.

Salah satu pendekatan dalam machine learning yang banyak digunakan untuk permasalahan klasifikasi adalah metode ensemble learning berbasis boosting. Metode ini bekerja dengan menggabungkan beberapa model pembelajaran sederhana untuk menghasilkan model prediksi yang lebih kuat dan stabil [6]. Di antara berbagai algoritma boosting yang berkembang, LightGBM (Light Gradient Boosting Machine) dikenal memiliki keunggulan dalam efisiensi komputasi, kecepatan pelatihan, serta kemampuan menangani dataset berukuran besar dengan hubungan nonlinier antar variabel. LightGBM menggunakan teknik pertumbuhan pohon yang memungkinkan model meminimalkan nilai loss secara

lebih optimal, sehingga berpotensi menghasilkan tingkat akurasi yang tinggi dalam proses klasifikasi [7].

Berdasarkan permasalahan tersebut, diperlukan suatu penelitian yang mampu merancang dan membangun model klasifikasi kelayakan penerima subsidi listrik pelanggan rumah tangga di wilayah PLN Aceh menggunakan metode Light Gradient Boosting Machine (LightGBM). Penelitian ini diharapkan dapat menghasilkan sistem klasifikasi berbasis data yang mampu meningkatkan objektivitas dan ketepatan sasaran penyaluran subsidi Listrik [8]. Dengan adanya model klasifikasi yang akurat, proses evaluasi penerima subsidi dapat dilakukan secara lebih efektif dan efisien, sehingga kebijakan subsidi listrik benar-benar dapat dirasakan oleh masyarakat yang berhak menerimanya serta mendukung pengelolaan anggaran subsidi energi secara lebih optimal [3].

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, maka rumusan masalah dari penelitian ini adalah:

1. Bagaimana merancang dan membangun model klasifikasi kelayakan penerima subsidi listrik berdasarkan data pelanggan PLN Aceh?
2. Bagaimana penerapan metode Light Gradient Boosting Machine (LightGBM) dalam mengklasifikasikan kelayakan penerima subsidi listrik pelanggan PLN Aceh?
3. Bagaimana hasil evaluasi model Light Gradient Boosting Machine

(LightGBM) dalam mengklasifikasikan kelayakan penerima subsidi listrik berdasarkan metrik pengujian yang digunakan?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis dan mengolah data pelanggan PLN Aceh yang digunakan dalam penentuan kelayakan penerima subsidi listrik.
2. Menerapkan metode Light Gradient Boosting Machine (LightGBM) untuk mengklasifikasikan kelayakan penerima subsidi listrik pada pelanggan PLN Aceh.
3. Mengetahui hasil klasifikasi kelayakan penerima subsidi listrik menggunakan metode LightGBM dalam mendukung ketepatan sasaran pemberian subsidi listrik.

1.4 Batasan Masalah

Agar penelitian ini lebih terfokus dan sesuai dengan tujuan yang ingin dicapai, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini dibatasi pada klasifikasi kelayakan penerima subsidi listrik pelanggan rumah tangga di wilayah PLN Aceh dengan fokus pada pelanggan daya 450 VA dan 900 VA sebagai kelompok utama penerima subsidi Listrik.
2. Data yang digunakan merupakan data pelanggan PLN Aceh dan data

pelanggan yang tercatat di Dinas Sosial yang mencakup daya listrik terpasang (VA), rata-rata konsumsi listrik bulanan (kWh), golongan tarif listrik, serta data sosial ekonomi yang tersedia.

3. Metode klasifikasi yang digunakan dalam penelitian ini adalah Light Gradient Boosting Machine (LightGBM), tanpa melakukan perbandingan dengan metode klasifikasi lainnya.
4. Output penelitian terbatas pada hasil klasifikasi kelayakan penerima subsidi listrik dan evaluasi performa model berdasarkan metrik evaluasi yang digunakan.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi keilmuan dalam penerapan algoritma Light Gradient Boosting Machine (LightGBM) untuk klasifikasi kelayakan penerima subsidi listrik.
2. Menghasilkan model klasifikasi berbasis data yang membantu penentuan penerima subsidi listrik secara lebih objektif dan tepat sasaran.
3. Mendukung peningkatan ketepatan sasaran subsidi listrik sehingga bantuan diberikan kepada masyarakat yang benar-benar membutuhkan.
4. Membantu meningkatkan efisiensi penggunaan anggaran subsidi listrik melalui pengurangan kesalahan penyaluran subsidi.

BAB II

TINJAUAN PUSTAKA

2.1 State of the Art

State of the Art bertujuan untuk memperkaya pembahasan penelitian serta membedakan penelitian ini dari penelitian-penelitian sebelumnya. Dalam penelitian ini, digunakan beberapa jurnal penelitian terdahulu yang berhubungan dengan klasifikasi dan penentuan kelayakan penerima subsidi listrik maupun bantuan sosial berbasis metode komputasi. Jurnal-jurnal tersebut antara lain:

1. Penelitian yang dilakukan oleh Yanto dan Yunus (2021) yang berjudul “Evaluasi Penentuan Kelayakan Pemberian Subsidi Listrik dengan Metode MFEP” membahas proses evaluasi kelayakan penerima subsidi listrik menggunakan metode Multi Factor Evaluation Process (MFEP). Metode ini melakukan pembobotan terhadap beberapa kriteria untuk menentukan tingkat kelayakan pelanggan. Hasil penelitian menunjukkan bahwa MFEP mampu membantu proses pengambilan keputusan secara sistematis berdasarkan faktor-faktor yang telah ditentukan. Persamaan penelitian tersebut dengan penelitian ini adalah sama-sama membahas penentuan kelayakan penerima subsidi listrik berdasarkan kriteria tertentu. Perbedaannya, penelitian tersebut menggunakan metode pembobotan manual berbasis MFEP, sedangkan penelitian ini menggunakan metode klasifikasi berbasis machine learning yang mampu mempelajari pola data secara otomatis sehingga diharapkan menghasilkan model prediksi yang

lebih optimal.

2. Hutahaean dan Wijayanto (2022) dalam penelitian berjudul “Klasifikasi Rumah Tangga Penerima Subsidi Listrik di Provinsi Gorontalo Tahun 2019 dengan Metode K-Nearest Neighbor dan Support Vector Machine” menerapkan dua algoritma klasifikasi, yaitu K-Nearest Neighbor (KNN) dan Support Vector Machine (SVM), untuk menentukan rumah tangga yang layak menerima subsidi listrik. Penelitian ini membandingkan performa kedua metode dalam menghasilkan tingkat akurasi terbaik. Hasil penelitian menunjukkan bahwa kedua metode mampu melakukan klasifikasi dengan tingkat akurasi yang baik pada dataset yang digunakan. Persamaannya dengan penelitian ini adalah sama-sama menggunakan pendekatan klasifikasi dalam menentukan penerima subsidi listrik. Perbedaannya, penelitian tersebut membandingkan dua metode sekaligus, sedangkan penelitian ini berfokus pada satu metode klasifikasi sehingga analisis dapat dilakukan lebih mendalam dan terfokus pada peningkatan performa model dan juga hasilnya lebih akurat.
3. Vionika Emalia Ismayana, Agung Panji Sasmito, dan Ali Mahmudi (2023) dalam penelitian berjudul “Sistem Penunjang Kelayakan Penerima Subsidi Program Keluarga Harapan (PKH) Menggunakan Metode Simple Additive Weighting (SAW) Berbasis Website (Studi Kasus: Desa Blimbing)” mengembangkan sistem pendukung keputusan untuk menentukan kelayakan penerima bantuan PKH menggunakan metode Simple Additive Weighting

(SAW). Metode SAW digunakan untuk melakukan pembobotan dan perangkingan berdasarkan sejumlah kriteria sosial ekonomi. Hasil penelitian menunjukkan bahwa sistem mampu memberikan rekomendasi penerima bantuan secara terstruktur. Persamaannya dengan penelitian ini adalah sama-sama bertujuan menentukan kelayakan penerima bantuan sosial berbasis kriteria tertentu. Perbedaannya, penelitian tersebut menggunakan metode pembobotan berbasis perhitungan statis, sedangkan penelitian ini menggunakan pendekatan klasifikasi machine learning yang lebih adaptif terhadap pola data.

4. Penelitian yang dilakukan oleh Fitriani, Sriani, dan Suhardi (2025) yang berjudul “Klasifikasi Penggunaan Daya Listrik Rumah Tangga Menggunakan Metode Naïve Bayes” membahas penerapan algoritma Naïve Bayes dalam mengklasifikasikan pelanggan listrik rumah tangga yang layak menerima subsidi. Penelitian ini menggunakan 720 data latih dengan variabel seperti daya listrik, luas bangunan, jenis lantai, dan kondisi tempat tinggal. Hasil penelitian menunjukkan tingkat akurasi sebesar 92%. Persamaannya dengan penelitian ini adalah sama-sama menggunakan metode klasifikasi untuk menentukan kelayakan subsidi listrik. Perbedaannya, penelitian tersebut menggunakan Naïve Bayes yang berbasis probabilitas dengan asumsi independensi antar variabel, sedangkan penelitian ini menggunakan metode klasifikasi yang mampu menangkap hubungan antar variabel secara lebih kompleks sehingga berpotensi

menghasilkan performa yang lebih baik.

5. (Sukerti, 2021) dalam penelitian berjudul “Sistem Penunjang Keputusan Penerima Bantuan Desa di Kecamatan Klungkung dengan Metode SAW” membahas perancangan sistem pendukung keputusan untuk menentukan desa yang layak menerima bantuan menggunakan metode Simple Additive Weighting (SAW). Penelitian ini bertujuan membantu pengambil keputusan dalam menentukan prioritas penerima bantuan berdasarkan kriteria tertentu. Hasil penelitian menunjukkan bahwa metode SAW dapat membantu proses seleksi secara lebih objektif. Persamaannya dengan penelitian ini adalah sama-sama membahas sistem penentuan kelayakan penerima bantuan. Perbedaannya, penelitian tersebut berfokus pada sistem pendukung keputusan berbasis pembobotan kriteria, sedangkan penelitian ini menggunakan pendekatan klasifikasi prediktif berbasis machine learning untuk meningkatkan akurasi dan kemampuan generalisasi model terhadap data baru.
6. Roudhotul Jannah dan Rastri Prativi (2026) dalam penelitian berjudul “Analisa Performa Metode LightGBM untuk Prediksi Kecanduan Media Sosial” membahas penerapan algoritma Light Gradient Boosting Machine (LightGBM) dalam memprediksi tingkat kecanduan media sosial berdasarkan berbagai indikator perilaku pengguna. Penelitian ini bertujuan untuk menganalisis performa model dari segi akurasi, presisi, dan efektivitas dalam menangani dataset. Persamaan penelitian tersebut dengan penelitian

ini adalah sama-sama menggunakan metode LightGBM sebagai algoritma klasifikasi/prediksi dalam membangun model berbasis machine learning. Perbedaannya, penelitian tersebut diterapkan pada kasus prediksi kecanduan media sosial, sedangkan penelitian ini berfokus pada klasifikasi penerima subsidi listrik berdasarkan variabel sosial ekonomi sehingga memiliki objek dan tujuan penelitian yang berbeda.

2.2 Tinjauan Teoritis

Tinjauan teoritis merupakan bagian yang menjelaskan konsep, teori, serta pendekatan ilmiah yang menjadi dasar dalam pelaksanaan penelitian. Pada penelitian ini, teori yang digunakan berkaitan dengan konsep klasifikasi dalam machine learning, pendekatan supervised dan unsupervised learning, kebijakan subsidi listrik di Indonesia, peran PT PLN dalam pengelolaan energi listrik, serta metode ensemble learning khususnya model boosting dan algoritma Light Gradient Boosting Machine (LightGBM). Seluruh teori tersebut menjadi landasan dalam membangun model klasifikasi kelayakan penerima subsidi listrik pelanggan PLN Aceh secara sistematis dan berbasis data.

2.2.1 Klasifikasi Dalam Machine Learning

Klasifikasi merupakan salah satu teknik utama dalam bidang data mining dan machine learning yang digunakan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan karakteristik yang dimiliki. Teknik ini bekerja dengan mempelajari pola hubungan antara variabel input dan label keluaran dari

data historis, kemudian menggunakan pola tersebut untuk memprediksi kelas pada data baru yang belum diketahui kategorinya [9]. Dalam konteks pengolahan data modern, klasifikasi menjadi metode yang banyak digunakan karena mampu membantu proses pengambilan keputusan secara objektif melalui analisis data. Model klasifikasi dibangun melalui proses pembelajaran (training) menggunakan dataset yang telah memiliki label kelas. Setelah model terbentuk, dilakukan pengujian menggunakan data testing untuk mengetahui kemampuan model dalam melakukan prediksi secara akurat.

Penerapan klasifikasi telah digunakan pada berbagai bidang, seperti diagnosis penyakit pada sektor kesehatan, analisis risiko kredit pada sektor keuangan, deteksi penipuan transaksi digital, hingga evaluasi kebijakan publik. Pada penelitian ini, teknik klasifikasi digunakan untuk menentukan status kelayakan pelanggan listrik rumah tangga dalam menerima subsidi listrik berdasarkan karakteristik data pelanggan yang tersedia.

Proses klasifikasi umumnya melibatkan beberapa tahapan utama, yaitu pengumpulan data, preprocessing data, pembentukan model, pengujian model, serta evaluasi performa menggunakan metrik tertentu. Kualitas hasil klasifikasi sangat dipengaruhi oleh kualitas data, pemilihan fitur, serta algoritma yang digunakan dalam proses pembelajaran mesin [10].

2.2.2 Supervised Learning dan Unsupervised Learning

Supervised learning merupakan metode pembelajaran mesin yang menggunakan data berlabel sebagai dasar pelatihan model. Pada metode ini, setiap

data memiliki pasangan input dan output yang telah diketahui sebelumnya, sehingga algoritma dapat mempelajari hubungan antara keduanya. Model yang dihasilkan kemudian digunakan untuk memprediksi output dari data baru [11]. Pendekatan supervised learning banyak digunakan pada permasalahan klasifikasi dan regresi karena mampu menghasilkan prediksi yang terarah sesuai target yang diinginkan. Dalam penelitian ini, pendekatan supervised learning digunakan karena data pelanggan PLN memiliki label kelayakan subsidi yang menjadi target prediksi. Model akan belajar dari data historis pelanggan untuk mengenali pola tertentu yang menunjukkan apakah seorang pelanggan layak atau tidak layak menerima subsidi listrik.

Sebaliknya, unsupervised learning merupakan metode pembelajaran mesin yang tidak menggunakan label kelas dalam proses pelatihannya. Algoritma pada pendekatan ini bertujuan menemukan pola tersembunyi atau struktur alami dalam data, seperti pengelompokan data berdasarkan kemiripan karakteristik. Metode ini umumnya digunakan untuk clustering, segmentasi pelanggan, dan analisis pola data. Meskipun unsupervised learning memiliki peran penting dalam eksplorasi data, pendekatan ini tidak digunakan dalam penelitian karena tujuan utama penelitian adalah melakukan klasifikasi berbasis label kelayakan subsidi yang telah ditentukan [12].

2.2.3 Subsidi Listrik di Indonesia

Subsidi listrik merupakan salah satu bentuk kebijakan pemerintah Indonesia dalam rangka meningkatkan kesejahteraan masyarakat serta menjamin akses

energi listrik yang merata. Kebijakan ini diberikan melalui penyesuaian tarif listrik sehingga masyarakat dengan kemampuan ekonomi terbatas tetap dapat memenuhi kebutuhan energi dasar dalam kehidupan sehari-hari.

Program subsidi listrik secara umum ditujukan kepada pelanggan rumah tangga dengan daya listrik rendah, terutama golongan 450 VA dan 900 VA. Kelompok pelanggan tersebut diasumsikan sebagai masyarakat berpenghasilan rendah yang membutuhkan dukungan pemerintah untuk mengurangi beban pengeluaran rumah tangga. Subsidi listrik menjadi bagian penting dari kebijakan perlindungan sosial karena listrik telah menjadi kebutuhan primer dalam aktivitas ekonomi dan sosial masyarakat modern [3].

Distribusi subsidi listrik masih menghadapi berbagai tantangan. Ketidaktepatan sasaran sering terjadi akibat keterbatasan metode identifikasi penerima subsidi yang masih berbasis indikator administratif sederhana. Kondisi ini menyebabkan adanya pelanggan yang secara ekonomi mampu tetapi tetap menerima subsidi, sementara sebagian masyarakat yang lebih membutuhkan justru tidak terdaftar sebagai penerima bantuan. Permasalahan tersebut menunjukkan perlunya pendekatan berbasis analisis data untuk membantu proses evaluasi kelayakan subsidi secara lebih objektif. Pemanfaatan teknik machine learning memungkinkan analisis berbagai variabel pelanggan secara simultan sehingga keputusan yang dihasilkan menjadi lebih akurat dan berbasis bukti data.

2.2.4 PT. PLN (Persero) Unit Induk Distribusi Aceh

PT PLN (Persero) merupakan perusahaan milik negara yang memiliki tanggung jawab utama dalam penyediaan tenaga listrik bagi masyarakat Indonesia. Sebagai penyedia layanan kelistrikan nasional, PLN berperan dalam produksi, distribusi, serta pengelolaan layanan pelanggan listrik di seluruh wilayah Indonesia, termasuk Provinsi Aceh. PLN Aceh mengelola berbagai data operasional pelanggan yang mencakup informasi daya listrik terpasang, golongan tarif, konsumsi energi listrik, serta status subsidi pelanggan. Data tersebut memiliki potensi besar untuk dianalisis lebih lanjut dalam mendukung kebijakan berbasis data, khususnya dalam evaluasi kelayakan penerima subsidi listrik.

Seiring perkembangan teknologi informasi, pemanfaatan data pelanggan menjadi salah satu strategi penting dalam meningkatkan kualitas pelayanan dan efisiensi operasional. Analisis data menggunakan metode machine learning dapat membantu PLN dalam mengidentifikasi pola konsumsi energi serta karakteristik pelanggan secara lebih mendalam. Dengan demikian, proses pengambilan keputusan terkait subsidi listrik dapat dilakukan secara lebih objektif, transparan, dan terukur.

2.2.5 Model Boosting dalam Machine Learning

Boosting merupakan salah satu teknik ensemble learning yang bertujuan meningkatkan performa model prediksi dengan menggabungkan beberapa model pembelajaran sederhana menjadi model yang lebih kuat. Konsep utama boosting

adalah membangun model secara bertahap, di mana setiap model baru berfokus memperbaiki kesalahan yang dihasilkan oleh model sebelumnya [8]. Pendekatan boosting bekerja secara iteratif dengan memberikan perhatian lebih besar pada data yang sebelumnya salah diklasifikasikan. Melalui proses ini, model secara bertahap mampu meningkatkan akurasi prediksi dan mengurangi kesalahan klasifikasi.

Metode boosting dikenal memiliki performa yang sangat baik dalam berbagai permasalahan klasifikasi karena mampu menangani hubungan kompleks dan nonlinier antar variabel. Beberapa algoritma boosting yang berkembang saat ini antara lain AdaBoost, Gradient Boosting Machine (GBM), XGBoost, dan LightGBM. Penggunaan model boosting menjadi semakin populer karena kemampuannya menghasilkan model dengan tingkat akurasi tinggi serta stabil terhadap variasi data.

2.2.6 Light Gradient Boosting Machine

Light Gradient Boosting Machine (LightGBM) merupakan salah satu algoritma machine learning berbasis boosting yang dirancang untuk menghasilkan prediksi dengan cepat dan akurat. Algoritma ini merupakan pengembangan dari Gradient Boosting Decision Tree (GBDT) dengan berbagai penyempurnaan agar proses pelatihan data menjadi lebih efisien dan tidak memerlukan banyak memori. LightGBM dikembangkan untuk mengatasi keterbatasan metode boosting konvensional, terutama ketika menangani dataset berukuran besar dan memiliki banyak variabel.

Salah satu keunggulan LightGBM terletak pada cara membangun pohon

keputusannya. LightGBM menggunakan teknik leaf-wise growth, yaitu memperluas cabang pohon yang memberikan penurunan kesalahan (loss) terbesar. Cara ini membuat proses pembelajaran menjadi lebih cepat dan mampu menangkap pola hubungan antar variabel yang lebih kompleks dibandingkan metode yang membangun pohon secara bertahap per level. Selain itu, LightGBM juga menggunakan pendekatan berbasis histogram sehingga proses pelatihan data menjadi lebih hemat memori dan lebih efisien.

Untuk meningkatkan kinerjanya, LightGBM menerapkan dua teknik utama. Pertama, Gradient-based One-Side Sampling (GOSS), yaitu memilih data yang paling berpengaruh terhadap proses pembelajaran sehingga model dapat fokus pada informasi yang penting. Kedua, Exclusive Feature Bundling (EFB), yaitu menggabungkan fitur-fitur yang jarang aktif agar jumlah variabel dapat dikurangi tanpa menghilangkan informasi yang relevan. Kombinasi teknik ini membuat LightGBM mampu bekerja lebih cepat tanpa mengurangi akurasi.

Berdasarkan karakteristik tersebut, LightGBM sangat sesuai digunakan dalam permasalahan klasifikasi yang melibatkan banyak atribut, seperti data pelanggan listrik. Dalam penelitian ini, LightGBM digunakan untuk membangun model klasifikasi kelayakan penerima subsidi listrik pelanggan PLN Aceh. Model yang dihasilkan diharapkan mampu mempelajari pola dari data historis pelanggan sehingga dapat memberikan prediksi yang lebih akurat, objektif, dan mendukung pengambilan keputusan yang lebih tepat dibandingkan metode manual.



Gambar 2.1 Metode Light Gradient Boosting Machine

Gambar 2.1 menunjukkan mekanisme pertumbuhan pohon keputusan pada metode Light Gradient Boosting Machine (LightGBM), yaitu menggunakan pendekatan leaf-wise tree growth. Pada metode ini, proses pengembangan pohon dilakukan dengan memilih cabang (leaf) yang memiliki nilai kesalahan (loss) terbesar untuk diperluas terlebih dahulu. Artinya, model akan memprioritaskan bagian pohon yang paling membutuhkan perbaikan sehingga proses pengurangan error dapat berlangsung lebih cepat dan efektif.

Berbeda dengan metode level-wise yang mengembangkan seluruh node pada satu tingkat secara bersamaan, pendekatan leaf-wise hanya memperluas satu cabang yang paling optimal pada setiap iterasi. Strategi ini membuat struktur pohon dapat tumbuh lebih dalam pada bagian tertentu yang dianggap penting oleh model. Akibatnya, LightGBM mampu menangkap pola hubungan antar variabel

yang lebih kompleks serta meningkatkan akurasi prediksi.

Pendekatan ini menjadi salah satu alasan mengapa LightGBM memiliki performa yang lebih cepat dan efisien dibandingkan metode boosting konvensional. Dengan fokus pada pengurangan error terbesar di setiap tahap, model dapat belajar dari data secara lebih terarah dan menghasilkan prediksi yang lebih optimal. Untuk memahami bagaimana LightGBM bekerja dalam proses pembelajaran model, terdapat beberapa rumus utama yang digunakan untuk mengoptimalkan fungsi objektif dan menentukan pemisahan (split) terbaik pada setiap node pohon keputusan. Rumus-rumus ini berperan dalam mengukur tingkat kesalahan model sekaligus mengontrol kompleksitas pohon agar tidak terjadi overfitting. Berikut adalah rumus inti yang digunakan dalam LightGBM:

1. Fungsi Objektif (Objective Function)

Fungsi objektif pada LightGBM dirumuskan sebagai berikut:

$$L = \sum_{i=1}^n l(y_i, \hat{y}_i) + \Omega(f) \quad (2.1)$$

Keterangan:

$l(y_i, \hat{y}_i)$ = fungsi loss (misalnya logloss untuk klasifikasi)

$\Omega(f)$ = fungsi regularisasi untuk mengontrol kompleksitas model

Fungsi regularisasi dirumuskan sebagai:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.2)$$

Keterangan:

T = jumlah daun (leaf) pada pohon

w_j = nilai output pada daun ke- j

γ = parameter penalty terhadap jumlah daun

λ = parameter regularisasi L2

Fungsi objektif ini bertujuan untuk meminimalkan kesalahan prediksi sekaligus menjaga agar model tidak terlalu kompleks. Regularisasi membantu mencegah overfitting dengan memberikan penalti pada jumlah daun dan besarnya bobot setiap daun.

2. Rumus Gain (Pemilihan Split Terbaik)

Untuk menentukan pemisahan node terbaik, LightGBM menggunakan perhitungan nilai gain sebagai berikut:

$$Gain = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (2.3)$$

Keterangan:

G_L, G_R = jumlah gradient pada sisi kiri dan kanan

H_L, H_R = jumlah hessia (gradien kedua) pada sisi kiri dan kanan

λ = parameter regularisasi L2

γ = penalti terhadap jumlah daun

Rumus gain ini digunakan untuk mengevaluasi apakah suatu pemisahan node memberikan peningkatan kualitas model atau tidak. Semakin besar nilai gain, maka semakin baik pemisahan tersebut dalam mengurangi error.

Melalui kombinasi fungsi objektif dan perhitungan gain tersebut, LightGBM mampu membangun struktur pohon keputusan secara efisien dan terarah. Fungsi objektif memastikan model tetap optimal dan tidak overfitting, sedangkan rumus gain membantu memilih pemisahan node terbaik pada setiap tahap pembentukan pohon. Dengan mekanisme ini, LightGBM dapat menghasilkan model klasifikasi yang cepat, stabil, dan memiliki performa tinggi pada berbagai jenis dataset.

BAB III

METODOLOGI PENELITIAN

3.1 Data dan Pengumpulan Data

Bagian ini menguraikan tahapan pengumpulan data yang menjadi dasar perancangan dan pelatihan model prediksi pada penelitian ini, mencakup lokasi dan periode pelaksanaan penelitian, alat serta bahan yang digunakan, variabel dan sumber data yang diolah, hingga proses analisis kebutuhan dan *preprocessing* data sebelum digunakan pada tahap pemodelan.

3.1.1 Tempat Penelitian

Penelitian dan pengembangan sistem *Point of Sale* (POS) dengan fitur prediksi penjualan harian menggunakan metode LSTM ini dilaksanakan pada beberapa lokasi yang mendukung proses perancangan, implementasi, dan pengujian, yaitu:

- 1. Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri**

Lhokseumawe: Menjadi lokasi utama dalam perancangan arsitektur sistem, penulisan kode program (aplikasi mobile Flutter dan REST API Python), pelatihan model LSTM, serta penyusunan laporan skripsi.

- 2. Departemen Teknik Elektro dan Informatika (DTEDI), Universitas**

Gadjah Mada: Sebagai penyedia dataset transaksi riil platform EatsTEDI UGM yang digunakan sebagai data latih dan data uji utama untuk mengevaluasi performa model prediksi LSTM.

3. Pelaku UMKM di Kota Lhokseumawe: Sebagai konteks sasaran pengguna yang melatarbelakangi analisis kebutuhan awal aplikasi kasir. Adapun pengumpulan data empiris (observasi, wawancara, dan dataset transaksi) serta pengujian sistem dilakukan pada mitra EatsTEDI DTEDI UGM, yang karakteristik operasionalnya (usaha kuliner skala mikro) dipandang merepresentasikan kebutuhan UMKM sejenis.

3.1.2 Waktu Penelitian

Penelitian ini dilaksanakan selama 4 (empat) bulan, terhitung mulai bulan Maret 2026 sampai dengan bulan Juni 2026. Alokasi waktu pelaksanaan untuk setiap tahapan penelitian disajikan pada Tabel 3.1.

Tabel 3.1 Jadwal Pelaksanaan Penelitian

No	Kegiatan	Maret 2026	April 2026	Mei 2026	Juni 2026
1	Persiapan dan Studi Literatur	✓			
2	Pengumpulan dan Analisis Data	✓	✓		
3	Perancangan Sistem dan UI/UX		✓		
4	Pengembangan Aplikasi POS Mobile		✓	✓	
5	Pelatihan dan Optimasi Model LSTM			✓	
6	Integrasi Sistem dan Pengujian			✓	✓
7	Evaluasi dan Penyusunan Laporan				✓

3.1.3 Alat dan Bahan

Untuk mendukung kelancaran pelaksanaan penelitian dan pengembangan sistem POS mobile, dibutuhkan alat (perangkat keras dan perangkat lunak) serta bahan penelitian dengan rincian yang disajikan pada Tabel 3.2.

Tabel 3.2 Daftar Alat dan Bahan Penelitian

No	Kategori	Nama Alat/Bahan	Spesifikasi / Deskripsi
1	Perangkat Keras (<i>Hardware</i>)	Laptop Acer Nitro 5	Intel Core i5 Gen 12, RAM 16 GB, SSD 512 GB, NVIDIA GeForce RTX 3050. Digunakan sebagai perangkat utama pengembangan aplikasi dan pelatihan model.

No	Kategori	Nama Alat/Bahan	Spesifikasi / Deskripsi
		Smartphone Android	OS Android 11. Digunakan untuk pengujian operasional aplikasi POS secara langsung di perangkat mobile.
		Printer Thermal	Bluetooth 58mm. Digunakan untuk menguji fungsionalitas cetak struk transaksi fisik.
2	Perangkat Lunak (<i>Software</i>)	Windows 11	Sistem Operasi Laptop (Home Single Language).
		VS Code & Android Studio	<i>Integrated Development Environment</i> (IDE) utama untuk penulisan kode program.
		Flutter SDK (Dart)	<i>Framework</i> lintas platform untuk membangun aplikasi kasir mobile.
		Python 3.10	Bahasa pemrograman dengan TensorFlow, Keras, PyTorch, Pandas, NumPy, Scikit-Learn, dan Flask untuk melatih model LSTM, membangun modul augmentasi data sintetis TimeGAN, dan membuat REST API prediksi.
		Supabase Cloud	Basis data <i>cloud</i> terpusat (PostgreSQL) untuk sinkronisasi data transaksi.
		Isar Database	Basis data lokal terbenam (<i>embedded</i>) pada perangkat Android (<i>offline-first</i>).
		Firebase	Layanan Google untuk <i>push notification</i> (FCM) dan telemetri (Analytics).
		Jupyter Notebook	Lingkungan <i>pipeline</i> riset untuk eksplorasi data dan pelatihan model prediksi.

No	Kategori	Nama Alat/Bahan	Spesifikasi / Deskripsi
		Hugging Face	Platform <i>hosting</i> tempat layanan API prediksi Flask di- <i>deploy</i> .
		Draw.io & Mermaid.js	Alat pemodelan sistem untuk membuat diagram UML, ERD, dan arsitektur.
3	Bahan Penelitian	Dataset EatsTEDI UGM	Berkas transaksi riil platform EatsTEDI DTEDI UGM dalam format SQL dump dan CSV (periode Agustus 2024 s.d. Juni 2026).

3.1.4 Variabel Data

Variabel penelitian yang digunakan dalam proses prediksi penjualan harian dikelompokkan menjadi tiga:

1. **Variabel *Input* (Fitur):** Deret waktu transaksi harian EatsTEDI yang terdiri atas *log-return* pendapatan, pengodean siklik (sinus–kosinus) untuk hari, minggu, dan bulan, serta penanda biner periode Ramadan. Variabel jumlah transaksi (*transactions*) dan kuantitas terjual (*qty_sold*) sengaja tidak digunakan sebagai fitur untuk menghindari kebocoran data (*data leakage*), karena keduanya belum tersedia saat memprediksi hari mendatang.
2. **Variabel *Output* (Target):** Nilai prediksi *log-return* pendapatan, yang direkonstruksi kembali ke nominal Rupiah sebagai acuan estimasi omzet harian dan kebutuhan stok produk.
3. **Variabel *Evaluasi*:** Kinerja model diukur dengan empat metrik evaluasi (MAE, RMSE, sMAPE, dan MASE). MAPE konvensional dihindari karena

menghasilkan nilai tak terhingga saat dihadapkan pada hari dengan pendapatan mendekati nol. Rincian formula masing-masing metrik dijabarkan pada Subbab 2.6.

3.1.5 Sumber Data

Data utama yang digunakan dalam penelitian ini adalah basis data transaksi penjualan harian yang bersumber dari platform katalog menu digital interaktif **EatsTEDI** pada Departemen Teknik Elektro dan Informatika (DTEDI) Universitas Gadjah Mada (UGM). *Dataset* ini berupa *dump* basis data relasional dalam format SQL (*eatstedi-20260621-010820.sql*) berukuran 32,15 MB dengan total sekitar 395.090 baris data.

Rentang waktu transaksi riil yang digunakan adalah dari tanggal **24 Agustus 2024 s.d. 20 Juni 2026** (mencakup periode 666 hari kalender secara inklusif, atau sekitar 22 bulan). Adapun hari aktif pertama dengan transaksi tercatat setelah penyaringan adalah **26 Agustus 2024**, sehingga Bab IV menyebut rentang efektif 26 Agustus 2024 s.d. 20 Juni 2026. Data yang diekstrak berfokus pada transaksi dengan status lunas (*is_paid = 1*) dari tabel *invoices* serta rincian item produk terjual dari tabel *product_sold* yang dihubungkan dengan tabel master *products* dan *categories*.

Secara umum, karakteristik data deret waktu (*time series*) EatsTEDI UGM memiliki pola musiman unik yang sangat dipengaruhi oleh kalender akademis kampus, antara lain:

1. **Pola Mingguan (*weekly profile*):** Penjualan aktif hampir 100%

terkonsentrasi pada hari kerja (Senin s.d. Jumat) dengan rata-rata 195,41 transaksi per hari aktif. Sedangkan pada hari Sabtu dan Minggu, transaksi umumnya bernilai Rp 0 karena kantin kampus tutup, dengan pengecualian sejumlah kecil transaksi insidental pada hari non-kerja.

2. **Pola Libur Akademis (*academic holiday profile*):** Pada masa libur semester mahasiswa (sepanjang bulan Januari dan Juli), transaksi bernilai Rp 0 karena aktivitas perkuliahan dan operasional kantin berhenti total.

3. **Pola Bulan Ramadan:** Omzet harian merosot tajam secara signifikan karena penutupan atau pembatasan jam operasional kantin selama bulan puasa (misalnya total omzet Maret 2025 hanya Rp 1.427.000,00 dan Maret 2026 sebesar Rp 3.531.000,00).

Selama periode transaksi tersebut, tercatat sebanyak **61.749 transaksi** lunas dengan total produk terjual sebanyak **150.709 unit** dan menghasilkan total akumulasi omzet sebesar **Rp 501.440.492,00**. Statistik agregat tersebut dihitung dari seluruh transaksi mentah pada rentang penuh, sebelum penyaringan kalender hari kerja diterapkan. Setelah penyaringan hanya pada hari kerja aktif (tanpa akhir pekan dan libur semester Januari/Juli), analisis model pada Bab IV menggunakan **313 hari aktif** dengan total omzet sebesar **Rp 471.200.494,00** dan rata-rata pendapatan sebesar **Rp 1.505.433,00 per hari aktif**. Selisih total omzet sebesar Rp 30.239.998,00 berasal dari transaksi insidental yang terjadi pada hari-hari di luar kalender hari kerja aktif (misalnya akhir pekan atau masa libur semester yang tetap mencatat penjualan), yang ikut tereliminasi oleh penyaringan kalender pada

tahap pemodelan.

Selain statistik agregat di atas, sebaran penjualan berdasarkan kategori produk pada platform EatsTEDI disajikan pada Tabel 3.3.

Tabel 3.3 Sebaran Penjualan Berdasarkan Kategori Produk

No	Kategori	Total Penjualan (Rp)	Total Unit	Kontribusi (%)
1	Makanan Basah	242.770.500,00	82.134	48,42%
2	Minuman	82.122.500,00	16.861	16,38%
3	Makanan Kering	41.969.500,00	10.361	8,37%
4	Ice Cream	33.802.500,00	10.942	6,74%
5	Snacks	26.671.500,00	10.847	5,32%
6	Merch	496.000,00	110	0,10%
7	Lainnya ¹	73.607.992,00	19.454	14,68%
	Total	501.440.492,00	150.709	100,00%

Berdasarkan sebaran tersebut, kategori **Makanan Basah** menyumbang kontribusi terbesar yakni sebesar 48,42% dari total akumulasi omzet. Karena sifat produk makanan basah yang memiliki masa simpan sangat singkat (*shelf life* pendek) dan cepat basi, ketidakpastian permintaan harian dapat berakibat langsung pada kerugian usaha akibat produk sisa yang terbuang. Oleh karena itu, prediksi penjualan harian dalam penelitian ini diprioritaskan pada kategori tersebut untuk membantu pelaku usaha dalam mengoptimalkan persediaan barang.

Adapun sepuluh produk terlaris berdasarkan kuantitas penjualan harian pada platform EatsTEDI dirinci pada Tabel 3.4.

Tabel 3.4 Daftar 10 Produk Terlaris EatsTEDI UGM

No	Nama Produk	Kuantitas Terjual (Unit)	Total Omzet (Rp)
1	Tahu Bakso	23.097	57.742.500,00
2	Tahu Bakso Balado	16.688	42.020.500,00
3	Risol Mayo & Sosis	8.489	21.717.000,00
4	Cheese/Banana Roll	3.417	3.417.000,00
5	Larist Air Mineral	3.020	12.080.000,00
6	Sandwich Crispy	2.796	11.184.000,00
7	Piscok	2.524	7.572.000,00
8	Ayam Krispi	2.495	6.237.500,00
9	Nasi Rames/Uduk	2.382	11.910.000,00
10	Donat	2.233	5.582.500,00

Adapun data dikumpulkan melalui tiga saluran utama:

1. **Observasi dan Wawancara:** Dilakukan terhadap pengelola divisi kewirausahaan mahasiswa platform EatsTEDI di Departemen Teknik Elektro dan Informatika UGM untuk memahami alur operasional kasir fisik, pencatatan menu harian, status stok, serta tantangan dalam mengantisipasi sisa stok makanan.
2. **Dokumentasi Transaksi:** Mengunduh dan mengekstrak basis data transaksi digital EatsTEDI dari file *dump* SQL untuk tabel *invoices*, *product_sold*, *products*, dan *categories* sebagai data latihan (*training data*) dan data uji (*testing data*) model prediksi LSTM.
3. **Studi Pustaka:** Mengkaji referensi jurnal ilmiah, buku manajemen operasi (Heizer & Render), serta dokumentasi teknis *framework* Flutter, TensorFlow LSTM, dan layanan Supabase sebagai landasan implementasi.

3.1.5.1 Ekstraksi dan Agregasi Data (Format CSV)

Proses transformasi data mentah dari basis data relasional *dump* SQL menjadi berkas terstruktur siap latih disebut sebagai proses ***Extract, Transform, and Load*** (ETL) atau **Ekstraksi dan Agregasi Data**. Tahapan ini dilakukan untuk mengubah granularitas data dari log transaksi individu (tingkat item terjual) menjadi deret waktu pendapatan harian, mingguan, dan bulanan yang sesuai dengan karakteristik input jaringan saraf LSTM.

Proses ekstraksi ini menghasilkan empat berkas dataset utama sebagai berikut:

1. ***raw_transactions.csv***: Berisi log transaksi gabungan hasil *join* tabel *invoices*, *product_sold*, *products*, dan *categories*.
2. ***daily_sales.csv***: Hasil agregasi harian yang menjadi dataset utama untuk model prediksi harian.
3. ***weekly_sales.csv***: Hasil agregasi mingguan untuk visualisasi tren mingguan.
4. ***monthly_sales.csv***: Hasil agregasi bulanan untuk analisis musiman jangka panjang.

Struktur skema data dan deskripsi kolom dari berkas *daily_sales.csv* sebagai dataset utama pelatihan model LSTM dirinci pada Tabel 3.5.

Tabel 3.5 Struktur Skema Dataset *daily_sales.csv*

Nama Kolom	Tipe Data	Deskripsi
<i>date</i>	Date	Tanggal transaksi (format YYYY-MM-DD).
<i>revenue</i>	Float	Total omzet pendapatan harian (nominal Rupiah).
<i>transactions</i>	Integer	Total volume transaksi/nota lunas harian.
<i>qty_sold</i>	Integer	Total kuantitas unit produk terjual harian.
<i>day_of_week</i>	Integer	Indeks hari dalam minggu (0 = Senin s.d. 6 = Minggu). Penyaringan hari kerja aktif (0 s.d. 4) dilakukan pada tahap pemodelan.
<i>week_of_year</i>	Integer	Nomor minggu dalam setahun berdasarkan standar ISO.
<i>month</i>	Integer	Nomor bulan kalender (1 s.d. 12).
<i>is_weekend</i>	Integer	Penanda biner akhir pekan (1 jika Sabtu/Minggu, 0 jika lainnya).
<i>is_holiday</i>	Integer	Penanda biner libur akademik (1 jika Januari/Juli, 0 jika aktif).
<i>is_ramadan</i>	Integer	Penanda biner bulan Ramadan (1 jika Ramadan, 0 jika lainnya).

Sementara itu, skema data untuk berkas agregasi mingguan *weekly_sales.csv* dan agregasi bulanan *monthly_sales.csv* masing-masing dijelaskan pada Tabel 3.6 dan Tabel 3.7.

Tabel 3.6 Struktur Skema Dataset *weekly_sales.csv*

Nama Kolom	Tipe Data	Deskripsi
<i>year_week</i>	String	Periode tahun dan nomor minggu ISO (format YYYY-WW).
<i>week_start</i>	Date	Tanggal awal hari Senin pada minggu tersebut (format YYYY-MM-DD).
<i>revenue</i>	Float	Total omzet pendapatan mingguan (nominal Rupiah).
<i>transactions</i>	Integer	Total volume transaksi/nota lunas mingguan.
<i>qty_sold</i>	Integer	Total kuantitas unit produk terjual mingguan.
<i>active_days</i>	Integer	Jumlah hari aktif beroperasi dalam minggu tersebut.

Tabel 3.7 Struktur Skema Dataset *monthly_sales.csv*

Nama Kolom	Tipe Data	Deskripsi
<i>year_month</i>	String	Periode tahun dan bulan kalender (format YYYY-MM).
<i>revenue</i>	Float	Total omzet pendapatan bulanan (nominal Rupiah).
<i>transactions</i>	Integer	Total volume transaksi/nota lunas bulanan.
<i>qty_sold</i>	Integer	Total kuantitas unit produk terjual bulanan.
<i>active_days</i>	Integer	Jumlah hari aktif beroperasi dalam bulan tersebut.

3.1.6 Analisis Kebutuhan Data

Analisis kebutuhan data dilakukan untuk mengidentifikasi karakteristik dan kebutuhan pemrosesan data agar model prediksi LSTM dan aplikasi POS dapat berintegrasi secara optimal:

1. **Volume Data Minimum (*Cold Start Mitigation*):** Model LSTM memerlukan data runtun waktu yang kontinu. Penelitian ini membedakan dua ambang batas yang berbeda tujuan: (1) **7 hari aktif** merupakan syarat

teknis minimum agar model dapat dijalankan sama sekali, sesuai panjang *sequence LOOK_BACK* pada arsitektur LSTM (lihat Subbab 3.2.7); dan (2) **30 hari aktif** merupakan ambang batas kualitas (*warm-up period*) agar hasil prediksi dianggap cukup andal untuk ditampilkan tanpa peringatan *cold start* kepada pengguna. Toko dengan riwayat transaksi kurang dari 7 hari tidak dapat memperoleh estimasi model sama sekali dan diberikan estimasi berbasis pola bisnis retail/kafe umum, sedangkan toko dengan riwayat antara 7–30 hari tetap memperoleh estimasi namun disertai peringatan *cold start* bahwa keandalannya masih terbatas.

2. **Pembersihan dan Imputasi Data:** Karena data mentah transaksi sering kali memiliki hari luring atau libur, diperlukan aturan pembersihan data. Hari non-aktif (Sabtu, Minggu, dan libur semester) disaring agar tidak mengacaukan analisis pola musiman bisnis harian.
3. **Keamanan Data (Minimalisasi Data):** *Payload* yang dikirimkan ke layanan REST API prediksi secara desain hanya berisi data agregat numerik penjualan (total omzet harian, kuantitas terjual, dan indeks waktu kalender) tanpa menyertakan informasi identitas pelanggan seperti nama, nomor telepon, maupun detail pembayaran spesifik, sehingga privasi pelanggan tetap terjaga.
4. **Struktur Payload Data API:** Data runtun waktu harus dikirimkan dalam format terstruktur JSON melalui protokol HTTPS. Payload berisi larik nominal omzet harian 7 hari terakhir beserta indeks waktu kalender yang

relevan.

3.1.7 Preprocessing Data

Data transaksi yang terkumpul dari basis data EatsTEDI melalui beberapa tahap penyiapan berikut sebelum digunakan untuk pelatihan model:

1. **Pembersihan dan Penyaringan Hari Aktif:** Menghapus data duplikat dan menyelaraskan format tanggal, serta menyaring hari non-aktif (Sabtu, Minggu, dan libur semester pada Januari dan Juli). Pada implementasinya, penyaringan diwujudkan dengan hanya mempertahankan hari kerja aktif yang memiliki pendapatan positif ($revenue > 0$). Penyaringan ini mencegah *gap* panjang pada deret waktu yang dapat mengaburkan pola musiman harian.
2. **Transformasi Target:** Nilai pendapatan ditransformasikan ke skala logaritma untuk menstabilkan variansi, kemudian diubah menjadi bentuk *log-return* (selisih logaritmik antar hari aktif) agar model mempelajari deviasi pendapatan relatif, bukan nilai nominal mentah.
3. **Normalisasi:** Seluruh fitur masukan diskalakan ke rentang $[0, 1]$ menggunakan *Min-Max Scaling*, dengan *fitting* parameter *scaler* hanya pada data latih untuk mencegah kebocoran informasi (*data leakage*).
4. **Pembentukan Sequence (Windowing):** Data diubah ke format *input-label* menggunakan *sliding window* sepanjang 7 hari kerja aktif ($LOOK_BACK = 7$) untuk memprediksi penjualan hari aktif berikutnya.
5. **Pembagian Data (Time-Based Split):** Dataset dibagi secara kronologis agar

urutan temporal terjaga dan tidak terjadi kebocoran data masa depan ke masa lalu.

Rincian teknis rumus *log-return*, *cyclical encoding*, dan arsitektur model dijabarkan secara lengkap pada Subbagian 3.2.7.

3.2 Rancangan Sistem

Perancangan sistem dalam penelitian ini dilakukan menggunakan pendekatan arsitektur terdistribusi dan pemodelan *Unified Modeling Language* (UML) untuk memberikan gambaran yang jelas mengenai arsitektur sistem, alur proses, dan interaksi pengguna. Pemodelan rancangan sistem direpresentasikan melalui arsitektur sistem, *Use Case Diagram*, *Class Diagram*, *Activity Diagram*, serta *Entity Relationship Diagram* (ERD).

3.2.1 Metode Penelitian

Penelitian ini merupakan jenis penelitian pengembangan (*Research and Development*) dengan pendekatan kuantitatif untuk pengujian model prediksi dan kualitatif untuk analisis kebutuhan pengguna. Model pengembangan yang digunakan adalah **Agile (Tangkas)** dengan pendekatan kombinasi antara **Iterative (Berulang)** dan **Incremental (Bertahap)**, serta mengadopsi prinsip **Lean Software Development**. Metode ini diterapkan melalui fase-fase berikut:

1. **Fokus pada *Minimum Viable Product* (MVP):** Pengembangan difokuskan pada penyelesaian fitur inti sistem kasir terlebih dahulu (*Core POS*, autentikasi pengguna, manajemen produk, dan integrasi *hardware printer*)

agar produk minimal dapat segera berfungsi untuk mempercepat waktu rilis ke pasar (*time-to-market*). Fitur lanjutan seperti analisis cerdas (*Smart Analytics*) dan notifikasi *push* direncanakan pada fase pasca-MVP.

2. **Pengembangan Berbasis Sesi/Iterasi Pendek (*sprints*):** Proses pengembangan dipecah menjadi siklus iterasi pendek dalam bentuk sesi-sesi harian terfokus. Setiap sesi ditujukan untuk menambahkan fungsionalitas baru (*increment*) secara bertahap atau melakukan optimasi spesifik, seperti perbaikan antarmuka dasbor, optimasi navigasi *sidebar*, dan penataan ulang modul *database*.
3. **Refaktorisasi Kode dan Adaptasi Perubahan:** Pengembangan bersifat adaptif dan responsif terhadap kendala teknis atau perubahan kebutuhan yang ditemui di tengah proses pengembangan. Siklus mencakup proses refaktorisasi kode mengikuti pembaruan standar *framework* Flutter, penyelarasan skema *database* (*schema alignment*), optimasi sinkronisasi data lokal-*cloud*, serta mitigasi kebocoran memori (*memory leaks*).
4. **Uji Coba Berulang (*Iterative Testing*):** Melakukan pengujian fungsionalitas menggunakan metode *Black Box Testing* secara berkala untuk setiap penambahan fitur baru untuk memastikan integritas dan stabilitas aplikasi kasir serta modul prediksi penjualan berbasis LSTM tetap terjaga.

3.2.1.1 Alur Penelitian

Alur penelitian ini dirancang secara sistematis untuk membangun sistem *Point of Sale* (POS) berbasis *mobile* yang dilengkapi fitur prediksi penjualan harian

menggunakan metode LSTM. Sebagaimana diilustrasikan pada Gambar 3.1, tahapan penelitian dibagi menjadi dua fase utama yang saling berkaitan.



Gambar 3.1 Alur Penelitian

Pada **Fase Pengembangan dan Implementasi Sistem POS**, penelitian diawali dengan analisis kebutuhan melalui observasi langsung dan identifikasi permasalahan pada mitra EatsTEDI. Selanjutnya dilakukan perancangan sistem meliputi arsitektur *offline-first*, desain basis data relasional (Supabase PostgreSQL dan Isar DB), serta perancangan *Use Case Diagram*, *Activity Diagram*, ERD, dan antarmuka pengguna. Setelah tahap perancangan, sistem POS dikembangkan menggunakan Flutter sebagai *frontend*, Supabase sebagai basis data *cloud*, Isar DB sebagai basis data lokal, dan layanan prediksi penjualan Python berbasis Flask yang di-*deploy* pada platform Hugging Face untuk pengolahan modul AI. Aplikasi yang telah dibangun kemudian diimplementasikan dan diujicobakan secara

fungsional pada mitra EatsTEDI untuk menguji kesesuaian alur transaksi kasir dan penyajian hasil prediksi kepada pengguna. Perlu ditegaskan bahwa data yang digunakan untuk melatih dan mengevaluasi model prediksi pada penelitian ini **bukan** berasal dari aplikasi Parzello POS yang baru dibangun tersebut, melainkan berupa data sekunder historis yang bersumber dari platform EatsTEDI yang telah beroperasi sebelumnya (*dump SQL eatstedi-20260621-010820.sql*), mencakup rentang waktu 24 Agustus 2024 s.d. 20 Juni 2026. Dengan demikian, aplikasi yang dibangun dalam penelitian ini berperan sebagai wadah penyajian hasil prediksi dan objek pengujian fungsional, sedangkan data latih model prediksi diperoleh dari riwayat transaksi mitra yang sudah ada jauh sebelum penelitian ini dimulai.

Pada **Fase Pengembangan Model Prediksi Penjualan**, data transaksi historis sekunder tersebut selanjutnya melalui tahap pra-pemrosesan meliputi pembersihan data, agregasi harian, normalisasi, dan pembentukan data deret waktu (*time series*). *Dataset* kemudian dibagi menjadi data latih dan data uji. Model LSTM dilatih menggunakan data latih untuk mempelajari pola penjualan jangka pendek maupun jangka panjang. Setelah pelatihan, model dievaluasi menggunakan metrik regresi deret waktu, yaitu MAE, RMSE, sMAPE, dan MASE, kemudian layanan prediksi produksi diintegrasikan ke dalam sistem POS sehingga aplikasi mampu menampilkan hasil prediksi penjualan harian kepada pengguna melalui *REST API*.

3.2.2 Diagram Use Case

Sistem POS melibatkan dua aktor utama, yaitu **Owner (Pemilik Toko)** dan **Kasir (Karyawan)**. *Use Case Diagram* menggambarkan fungsi-fungsi yang dapat diakses oleh masing-masing aktor. Pembatasan hak akses berbasis peran (*Role-Based Access Control/RBAC*) ditegakkan pada lapisan navigasi aplikasi (*router.dart*), di mana hanya rute Manajemen Karyawan dan Pengaturan Profil Toko yang dibatasi eksklusif untuk Owner, sedangkan fungsi operasional lainnya dapat diakses oleh seluruh staf toko. Rancangan *use case* diilustrasikan pada Gambar 3.2.

A large rectangular frame with a thin gray border. Inside the frame, two diagonal lines cross at the center, forming an 'X' shape. In the middle of the frame, there is a horizontal rounded rectangle with a thin gray border. Inside this rounded rectangle, the text "Gambar Tidak Ditemukan" is written in a bold, black, sans-serif font.

Gambar Tidak Ditemukan

1. Definisi Aktor

Definisi aktor pada sistem POS diilustrasikan pada Tabel 3.8 berikut:

Tabel 3.8 Definisi Aktor

No.	Aktor	Deskripsi
1	Owner (Pemilik)	Aktor dengan hak akses penuh terhadap seluruh sistem. Hak eksklusif Owner pada lapisan navigasi adalah manajemen data karyawan dan pengaturan identitas toko. Owner juga menjadi penanggung jawab utama konfigurasi toko dan pengambilan keputusan strategis berbasis laporan serta fitur AI <i>Smart Analytics</i> .
2	Kasir (Karyawan)	Staf operasional harian toko dengan akses mencakup pelayanan penjualan (POS), pencetakan struk, manajemen produk dan kategori, audit riwayat stok, <i>dashboard</i> , laporan penjualan, <i>broadcast</i> notifikasi, serta AI <i>Smart Analytics</i> , kecuali manajemen karyawan dan pengaturan profil toko yang tetap eksklusif Owner.

2. Definisi Use Case

Definisi *use case* pada sistem POS diilustrasikan pada Tabel 3.9 berikut:

Tabel 3.9 Definisi Use Case

No.	Use Case	Deskripsi
1	Registrasi Toko Baru	Mendaftarkan akun toko baru saat inisialisasi awal sistem (Owner).
2	<i>Login</i> Akun	Autentikasi pengguna menggunakan email dan kata sandi via Supabase Auth.
3	Melakukan <i>Checkout</i>	Memasukkan produk ke keranjang dan memproses transaksi pembayaran.
4	Menerapkan <i>Voucher/Diskon</i>	Memasukkan kode promosi untuk memotong total tagihan transaksi.

No.	Use Case	Deskripsi
5	Melakukan <i>Split Bill</i>	Memecah pembayaran satu nota belanja menjadi beberapa bagian tagihan, terintegrasi di lembar keranjang dan layar pembayaran.
6	Mencetak Struk	Mencetak struk transaksi fisik via printer <i>thermal</i> Bluetooth.
7	Memonitor Status Meja	Memantau keterisian meja secara visual, terintegrasi di dalam alur POS.
8	Mengelola Katalog Produk	Menambah, menyunting, dan menghapus produk/stok barang.
9	Mengelola Kategori	Mengatur pengelompokan menu katalog produk toko.
10	Mengaudit Riwayat Stok	Melihat <i>log</i> mutasi stok untuk keperluan audit inventaris.
11	Melihat <i>Dashboard</i>	Memantau performa keuangan dan statistik penjualan toko.
12	Melihat <i>AI Smart Analytics</i>	Mengakses proyeksi penjualan berbasis Model LSTM beserta riwayat hasil analitik sebelumnya.
13	Kirim <i>Broadcast</i> Notifikasi	Mengirim pemberitahuan <i>real-time</i> ke staf toko.
14	Sinkronisasi Data	Menyinkronkan transaksi <i>offline</i> lokal ke <i>cloud</i> Supabase secara otomatis.
15	Mengelola Karyawan	Mendaftarkan atau mengubah peran staf kasir (Owner).
16	Mengatur Profil Toko	Mengubah nama toko, alamat, dan logo outlet (Owner).

3.2.3 Arsitektur Sistem

Sistem Parzello POS Mobile dirancang menggunakan pendekatan arsitektur *hybrid-cloud* yang membagi pemrosesan antara perangkat lokal dan infrastruktur *cloud*. Secara keseluruhan, sistem terdiri dari empat komponen utama yang saling terintegrasi, yaitu *Flutter Mobile App*, *Supabase Cloud*, *Firebase*, dan *Layanan*

Inferensi Model LSTM (Hugging Face). Rancangan arsitektur sistem diilustrasikan pada Gambar 3.3.



Gambar 3.3 Arsitektur Sistem POS

Penjelasan mengenai empat komponen utama dalam arsitektur sistem adalah sebagai berikut:

1. **Sisi Klien (*Client-Side*):** Aplikasi dibangun menggunakan *framework* Flutter dengan manajemen *state* Riverpod dan navigasi GoRouter. Komponen inti dari sisi klien adalah Isar DB, sebuah database NoSQL lokal yang berperan sebagai *cache offline-first*, memungkinkan kasir tetap dapat melakukan transaksi penuh meskipun koneksi internet terputus. *Sync Engine* kemudian bekerja di latar belakang untuk menyinkronkan data lokal ke *cloud* secara otomatis ketika koneksi terdeteksi kembali aktif, menggunakan penanda *isSynced* pada setiap *record* untuk menghindari duplikasi data.

Selain itu, sisi klien juga mengelola integrasi perangkat keras berupa printer *thermal* Bluetooth/USB untuk mencetak struk dan kamera untuk pemindaian *barcode* produk.

2. **Infrastruktur Cloud (Supabase):** Sebagai tulang punggung infrastruktur *cloud*, Supabase menyediakan empat layanan utama. Supabase Auth menangani autentikasi pengguna melalui protokol JWT dan Google OAuth. Supabase PostgreSQL menjadi basis data relasional terpusat yang dilengkapi kebijakan *Row Level Security* (RLS) untuk mengisolasi data antar *merchant*, pemicu database (*triggers*), serta prosedur tersimpan (*RPC*) untuk memproses transaksi secara aman. Supabase Storage menyimpan aset media seperti gambar produk dan logo toko. Sedangkan *Edge Functions* digunakan untuk memproses *webhook* basis data yang bersifat sensitif, seperti pemicu pengiriman *push notification* peringatan stok menipis kepada pemilik toko.
3. **Telemetri dan Notifikasi (Firebase):** Untuk kebutuhan telemetri dan notifikasi, sistem terintegrasi dengan Firebase. *Firebase Cloud Messaging* (FCM) bertugas menyampaikan *push notification* secara *real-time* kepada pemilik toko, misalnya peringatan stok habis atau pembatalan transaksi oleh kasir. *Firebase Analytics* digunakan untuk mencatat perilaku penggunaan aplikasi, seperti volume transaksi harian, penggunaan fitur *split bill*, dan inisiasi kalibrasi model AI.
4. **Layanan Inferensi Model LSTM (Hugging Face):** Komponen terakhir adalah layanan inferensi untuk mendukung fitur analitik prediktif. Pada

penelitian ini, dikembangkan sebuah model *deep learning* berbasis **Long Short-Term Memory (LSTM)** secara mandiri, yang dirancang khusus untuk memproyeksikan data runtun waktu (*time-series*) penjualan harian pada usaha berskala UMKM. Model prediksi tersebut kemudian dikemas dalam layanan prediksi penjualan berbasis *REST API* (*framework* Flask) yang di-*deploy* pada platform Hugging Face, sehingga dapat diakses oleh sistem secara efisien tanpa memerlukan infrastruktur *server* komputasi tersendiri. Ketika pengguna mengakses fitur *Smart Analytics*, aplikasi Flutter memanggil *endpoint* layanan prediksi tersebut secara langsung melalui protokol HTTPS (dikonfigurasi pada berkas *env.dart* dan dapat dioverride saat *build* melalui *-dart-define*), dengan *payload* berupa data agregat penjualan tanpa informasi identitas pelanggan. Model memproses data tersebut dan mengembalikan hasil prediksi dalam format JSON, mencakup estimasi omzet harian, prediksi produk terlaris, serta rekomendasi promosi berbasis stok, yang selanjutnya divisualisasikan melalui antarmuka grafik interaktif menggunakan pustaka *fl_chart*. Aplikasi juga menangani kondisi *cold start*, yaitu menampilkan peringatan pemuatan ketika *server* inferensi baru aktif kembali dari kondisi *idle*. Setiap hasil analisis disimpan sebagai *snapshot* pada tabel *smart_analytics_snapshots* di Supabase, sehingga riwayat analitik dapat ditinjau kembali tanpa perlu memanggil ulang model.

3.2.4 Class Diagram

Class Diagram menggambarkan struktur sistem dari segi pendefinisian kelas-kelas yang akan dibangun beserta atribut dan metodenya, serta hubungan relasi asosiasi antar-kelas. Pada aplikasi Parzello POS Mobile, rancangan kelas didasarkan pada koleksi basis data lokal Isar DB yang digunakan untuk mendukung penyimpanan *offline-first*. Struktur kelas-kelas ini disajikan pada Gambar 3.4.



Gambar 3.4 Class Diagram Sistem POS

Penjelasan mengenai kelas-kelas utama dalam sistem adalah sebagai berikut:

1. **Store:** Merepresentasikan informasi toko/outlet, memiliki relasi satu-ke-banyak dengan Kategori, Produk, dan Transaksi.
2. **Category:** Mengelompokkan produk ke dalam kategori tertentu.

3. **Product:** Menyimpan informasi detail produk termasuk nama, harga jual, harga modal, dan stok.
4. **TransactionLocal:** Menyimpan rangkuman transaksi penjualan kasir di perangkat klien.
5. **TransactionItemLocal:** Menyimpan baris item produk detail dari setiap transaksi belanja.

3.2.5 Activity Diagram

Activity Diagram merupakan gambaran visual dalam bentuk diagram yang digunakan untuk menggambarkan serangkaian aktivitas atau proses yang terjadi di dalam sistem. Diagram ini memudahkan dalam menjelaskan logika prosedural, proses bisnis, serta alur kerja sistem Parzello POS Mobile yang dilengkapi dengan fitur prediksi penjualan harian. Adapun *Activity Diagram* pada sistem ini dijelaskan sebagai berikut.

1. Activity Diagram Alur Kerja Transaksi Kasir (POS Checkout)

Gambar 3.5 menggambarkan alur kerja kasir atau *owner* dalam memproses transaksi belanja pelanggan di kasir, termasuk opsi penerapan kupon/voucher diskon dan pemisahan tagihan (*split bill*) yang terintegrasi langsung di dalam lembar keranjang belanja dan layar pembayaran, sebelum data disimpan di penyimpanan lokal Isar DB.



Gambar 3.5 Activity Diagram Alur Kerja Transaksi Kasir

2. Activity Diagram Sinkronisasi Latar Belakang (Offline-First Sync Engine)

Gambar 3.6 menggambarkan logika sinkronisasi data dari *local database* (Isar DB) ke cloud database (Supabase) secara otomatis saat status konektivitas terdeteksi *online*. Alur data dilakukan berdasarkan ketergantungan relasi tabel (kategori, produk, transaksi, riwayat stok) untuk menjaga konsistensi, di mana pengunggahan transaksi dilakukan melalui pemanggilan prosedur RPC *create_transaction_v4* pada PostgreSQL agar pencatatan nota dan pemotongan stok di *cloud* berlangsung dalam satu transaksi basis data yang aman.



Gambar 3.6 Activity Diagram Sinkronisasi Latar Belakang

3. Activity Diagram Proses AI Smart Analytics

Gambar 3.7 menggambarkan alur kerja fitur analitik prediktif: pengguna membuka layar *Smart Analytics*, sistem mengagregasi data penjualan historis dari Isar DB lokal, lalu memanggil *endpoint* model LSTM yang di-*hosting* di Hugging Face secara langsung melalui HTTPS. Selama pemrosesan, sistem menampilkan status pemuatan (termasuk peringatan *cold start* bila *server* inferensi baru aktif dari kondisi *idle*), kemudian merender visualisasi analitik omzet beserta rekomendasi promosi, dan menyimpan hasilnya sebagai *snapshot* riwayat analitik di tabel *smart_analytics_snapshots*.



Gambar 3.7 Activity Diagram Proses AI Smart Analytics

4. Activity Diagram Kelola Produk (Tambah/Ubah/Hapus)

Gambar 3.8 menggambarkan alur kerja staf toko dalam mengelola katalog produk yang menjadi sumber data transaksi bagi model prediksi penjualan. Proses tambah/ubah data disimpan terlebih dahulu ke basis data lokal Isar DB (*offline-first*) beserta pencatatan riwayat perubahan stok, sebelum disinkronkan ke Supabase saat koneksi *online* tersedia. Proses hapus produk diterapkan melalui skema *soft delete* lokal (penanda *isDeleted=true*) yang baru dihapus permanen dari basis data setelah sinkronisasi ke *cloud* berhasil, guna menjaga konsistensi data penjualan yang menjadi masukan pemodelan LSTM.



Gambar 3.8 Activity Diagram Kelola Produk (Tambah/Ubah/Hapus)

3.2.6 *Entity Relationship Diagram (ERD)*

Basis data sistem POS dirancang secara hibrida menggunakan Supabase PostgreSQL untuk penyimpanan *cloud* dan Isar DB untuk penyimpanan lokal di perangkat *mobile*. Skema basis data *cloud* terdiri dari sembilan entitas utama yang saling berelasi sebagaimana diilustrasikan pada Gambar 3.9.



Gambar 3.9 *Entity Relationship Diagram* (ERD) Sistem POS


Entitas *stores* menjadi entitas induk yang berelasi dengan seluruh entitas lainnya. Entitas *store_members* mengelola hak akses berbasis peran (*Role-Based Access Control*/RBAC) untuk Owner dan Kasir. Katalog produk dikelola melalui entitas *products* dan *categories*, sedangkan data transaksi disimpan pada entitas *transactions* dan *transaction_items*. Riwayat perubahan stok dicatat pada entitas *stock_history*, sementara entitas *notifications* mendukung sistem notifikasi. Adapun hasil analisis fitur *AI Smart Analytics* disimpan sebagai riwayat *snapshot* pada entitas *smart_analytics_snapshots*. Daftar seluruh tabel basis data yang digunakan dirangkum pada Tabel 3.10.

Tabel 3.10 Daftar Tabel Basis Data POS

No.	Nama Tabel	Deskripsi
1	<i>stores</i>	Menyimpan data identitas dan konfigurasi outlet toko <i>merchant</i> .
2	<i>store_members</i>	Mengelola hak akses dan peran staf (Owner/Kasir) pada setiap toko.
3	<i>categories</i>	Menyimpan kategori pengelompokan produk atau menu dagangan.
4	<i>products</i>	Menyimpan katalog produk beserta harga, stok, dan data SKU/ <i>barcode</i> .
5	<i>transactions</i>	Menyimpan data nota transaksi penjualan kasir sebagai tabel induk.
6	<i>transaction_items</i>	Menyimpan rincian produk yang dibeli dalam setiap transaksi.
7	<i>stock_history</i>	Mencatat <i>log</i> audit perubahan stok masuk dan keluar produk.
8	<i>notifications</i>	Menyimpan pesan notifikasi sistem dan <i>broadcast</i> antar staf toko.
9	<i>smart_analytics_snapshots</i>	Menyimpan riwayat <i>snapshot</i> hasil analitik prediksi LSTM setiap kali fitur <i>Smart Analytics</i> dijalankan.

3.2.7 Rancangan Algoritma *Long Short-Term Memory* (LSTM)

Desain metode LSTM memberikan gambaran mengenai alur kerja algoritma yang digunakan dalam proses prediksi penjualan harian pada sistem POS. Alur kerja algoritma diilustrasikan pada Gambar 3.10.



Gambar 3.10 Alur Kerja Algoritma *Long Short-Term Memory* (LSTM)

Gambar 3.10 menggambarkan alur kerja model LSTM dari *input* data

transaksi harian hingga proses evaluasi model. Adapun penjelasan rinci mengenai tahapan algoritma LSTM yang dirancang dalam penelitian ini adalah sebagai berikut:

1. **Pra-pemrosesan Data dan Transformasi Target:** Data transaksi harian ditarik dari database cloud Supabase. Langkah-langkah pra-pemrosesan yang dilakukan meliputi:

- *Filtering hari non-aktif (Zero Days):* Menghapus hari Sabtu, Minggu, serta bulan Januari dan Juli (libur semester kampus) untuk menghindari distorsi gap yang panjang pada deret waktu. Model dilatih murni menggunakan indeks hari kerja aktif (*business days*).
- *Transformasi Logaritma:* Data nominal pendapatan Y_t ditransformasikan ke skala logaritma menggunakan $Y'_t = \log(Y_t + 1)$ untuk menstabilkan variansi.
- *Transformasi Target (Log-Return):* Model tidak memprediksi pendapatan logaritmik secara langsung, melainkan memprediksi perubahan pendapatan relatif (*log-return*) r_t menggunakan pendekatan *hybrid residual* sebagaimana dirumuskan pada Subbab 2.4.1, agar model mewarisi sifat autokorelasi jangka pendek yang dominan pada data penjualan.
- *Pengodean Siklik:* Fitur waktu (*day of week, week of year, month*) diubah menjadi nilai sinus dan kosinus untuk merepresentasikan sifat periodik kalender.

- *Normalisasi*: Fitur-fitur masukan dinormalisasi menggunakan *Min-Max Scaling* ke rentang $[0, 1]$, di mana proses pemasangan (*fitting*) parameter *scaler* hanya dilakukan pada data latih (*training set*) untuk mencegah kebocoran informasi (*data leakage*).

2. **Pembentukan Sequence (Sliding Window)**: Dataset deret waktu diubah menjadi bentuk urutan berpasangan (*sequence pairs*) menggunakan metode *sliding window*. Ukuran *window* masukan (*look-back*) ditetapkan sebesar 7 hari aktif terakhir ($LOOK_BACK = 7$) untuk memprediksi target 1 hari aktif berikutnya ($HORIZON = 1$). Dengan demikian, model dilatih dengan format prediksi satu langkah ke depan (*one-step-ahead prediction*).

3. **Pembagian Dataset Kronologis**: Dataset dibagi secara kronologis (*time-based split*) untuk menjaga integritas temporal deret waktu, dengan proporsi pembagian sebagai berikut:

- *Data Latih (Training Set)*: Sebesar 70% dari total data aktif (periode Agustus 2024 s.d. Agustus 2025).
- *Data Validasi (Validation Set)*: Sebesar 15% (periode September s.d. Desember 2025) digunakan untuk pemantauan proses latih dan *early stopping*.
- *Data Uji (Testing Set)*: Sebesar 15% (efektif periode Februari s.d. Juni 2026, karena Januari tersaring sebagai libur semester) digunakan untuk pengujian akhir model.

4. **Pembangunan Arsitektur LSTM Tersederhanakan**: Untuk menghindari

masalah *overfitting* dan *model collapse* pada dataset yang relatif kecil, arsitektur LSTM dirancang secara minimalis (*shallow network*):

- *Input Layer*: Menerima matriks berukuran 7×8 (panjang *sequence* 7 dan total 8 fitur masukan).
- *LSTM Layer*: Terdiri atas 1 layer LSTM dengan 24 *hidden units*.
- *Dropout Layer*: Dengan laju 0,1 untuk mencegah ketergantungan berlebih antar-node.
- *Dense Layer*: Terdiri atas 16 neuron dengan fungsi aktivasi *Rectified Linear Unit* (ReLU).
- *Output Layer*: Terdiri atas 1 neuron (*Dense* dengan aktivasi linear) untuk memprediksi nilai *log-return* $\hat{r}_t$.

Model ini memiliki total parameter terlatih sebanyak 3.585 parameter, yang sebanding dengan ukuran data latih.

5. **Pelatihan Model:** Model dilatih menggunakan algoritma optimasi Adam dengan *learning rate* awal sebesar 5×10^{-4} dan fungsi kerugian (*loss function*) *Mean Squared Error* (MSE). Untuk mengoptimalkan konvergensi, diterapkan dua mekanisme *callback*:

- *Early Stopping*: Menghentikan pelatihan jika loss validasi tidak membaik selama 20 *epoch* berturut-turut untuk mencegah *overfitting*, serta mengembalikan bobot terbaik (*restore best weights*).
- *Reduce Learning Rate on Plateau*: Mengurangi *learning rate* sebesar faktor 0,5 jika loss validasi mendatar selama 8 *epoch*.

Ukuran *batch* pelatihan diatur sebesar 16 dengan jumlah maksimum pelatihan 200 *epoch*.

6. **Evaluasi Komparatif dan Multi-Seed:** Untuk membuktikan keandalan model LSTM, kinerjanya dibandingkan dengan empat model pembanding (*baseline*):

- *Naive (Kemarin)*: Prediksi hari ini dianggap sama dengan nilai penjualan riil hari aktif sebelumnya.
- *Mean-7*: Prediksi berupa rata-rata bergerak dari 7 hari aktif terakhir.
- *SARIMA*: Model statistik klasik Seasonal Autoregressive Integrated Moving Average untuk mendeteksi pola autokorelasi deret waktu.
- *Seasonal-Naive*: Prediksi berupa rata-rata beberapa kemunculan terakhir dari hari yang sama dalam minggu (Senin dengan Senin, Selasa dengan Selasa, dan seterusnya), untuk menangkap pola musiman mingguan.

Dari keempat *baseline* tersebut, *Naive*, *Mean-7*, dan *SARIMA* dievaluasi pada skema satu langkah ke depan (*one-step-ahead*), sedangkan *Seasonal-Naive* dievaluasi pada skema prediksi multi-langkah dan menjadi kandidat metode penyaji pada layanan API produksi. Notasi parameter *Seasonal-Naive* dilambangkan dengan k , yaitu jumlah kemunculan terakhir hari sejenis yang dirata-ratakan. Selain prediksi harian sebagai fokus evaluasi ilmiah, layanan API produksi juga menyajikan angka proyeksi mingguan dan bulanan menggunakan metode rata-rata sederhana (*Mean-4*

untuk empat minggu terakhir dan *Mean-3* untuk tiga bulan terakhir). Keduanya merupakan fitur pelengkap visualisasi aplikasi di luar lingkup evaluasi ilmiah penelitian ini, sejalan dengan Batasan Masalah yang memfokuskan prediksi pada rentang harian.

Mengingat inisialisasi bobot awal jaringan saraf bersifat acak dan dapat memengaruhi stabilitas pada data kecil, evaluasi dilakukan menggunakan metode ***Multi-Seed Evaluation***. Model dilatih sebanyak 10 kali menggunakan *seed* acak yang berbeda. Hasil evaluasi dilaporkan dalam bentuk rata-rata $\pm$ standar deviasi dari metrik MAE, RMSE, sMAPE, dan MASE guna memperoleh estimasi performa yang kokoh dan dapat dipertanggungjawabkan.

7. **Eksperimen Augmentasi Data Sintetis (TimeGAN):** Sebagai upaya mitigasi terhadap keterbatasan jumlah data latih, dirancang skenario eksperimen augmentasi data sintetis menggunakan **TimeGAN** (*Time-series Generative Adversarial Networks*), yaitu arsitektur GAN khusus deret waktu yang diusulkan oleh Yoon et al. (2019). TimeGAN diimplementasikan menggunakan *framework* PyTorch dan terdiri atas lima jaringan saraf (*embedder*, *recovery*, *generator*, *supervisor*, dan *discriminator*) yang dilatih dalam tiga fase: (1) pelatihan *autoencoder* (*embedder*–*recovery*), (2) pelatihan *supervised* pada ruang laten, dan (3) pelatihan gabungan (*joint training*) secara *adversarial*. Model dilatih pada jendela deret waktu sepanjang 24 hari aktif dengan tiga fitur numerik (omzet, jumlah transaksi,

dan kuantitas terjual), kemudian menghasilkan 298 sekuens data harian sintetis dari 199 sekuens data riil (rasio augmentasi 1,5). Data sintetis tersebut digabungkan dengan data riil untuk melatih ulang model LSTM (skenario *augmented*), lalu performanya dibandingkan terhadap model LSTM tanpa augmentasi dan *baseline Seasonal-Naive* guna mengukur seberapa besar augmentasi data mampu memperbaiki akurasi prediksi pada data terbatas.

8. **Rekonstruksi dan Prakiraan Rekursif Multi-Langkah:** Output model berupa *log-return* prediksi ($\hat{r}_t$) direkonstruksi kembali ke skala nominal Rupiah ($\hat{Y}_t$) menggunakan nilai penjualan hari sebelumnya (Y_{t-1}) sesuai formula rekonstruksi pada Subbab 2.4.1. Untuk menyajikan proyeksi 7 hari aktif ke depan pada aplikasi POS, diterapkan metode ***Recursive Forecasting*** (memasukkan hasil prediksi langkah sebelumnya sebagai input untuk langkah berikutnya). Untuk mencegah masalah akumulasi bias (*error propagation*) yang dapat menyebabkan nilai prediksi meluruh atau meledak, diimplementasikan tiga teknik pengaman:

- *Clipping log-return*: Membatasi nilai prediksi *log-return* pada rentang persentil 10–90 dari data pelatihan untuk mencegah nilai ekstrem.
- *Damping factor*: Meredam prediksi perubahan *log-return* pada langkah ke- h menuju nilai 0 dengan faktor peredam ϕ^h (di mana $\phi = 0.7$). Hal ini membuat ramalan jangka panjang stabil dan kembali ke nilai rata-rata historis (sifat *mean-reverting*).

- *Safety rail*: Membatasi hasil akhir nominal pendapatan berada dalam rentang pendapatan terkecil dan terbesar yang pernah tercatat secara historis pada hari aktif.

3.2.8 Perancangan *Wireframe*

Perancangan *wireframe* dalam penelitian ini mencakup rancangan antarmuka pengguna untuk semua layar utama yang menjadi bagian dari alur operasional aplikasi POS. *Wireframe* dirancang dengan mempertimbangkan kebutuhan pengguna, aksesibilitas, dan alur kerja yang efisien. Terdapat 13 rancangan layar yang melayani kebutuhan berbeda sesuai dengan peran pengguna, sebagaimana diuraikan berikut ini.

1. Halaman Registrasi Toko Baru

Halaman pendaftaran akun dan toko baru yang digunakan saat inisialisasi awal sistem oleh Owner, mencakup pengisian data identitas pengguna dan informasi outlet toko.



Gambar 3.11 *Wireframe* Halaman Registrasi Toko Baru

2. Halaman *Login*

Halaman masuk akun untuk Owner maupun Kasir dengan autentikasi berbasis email dan kata sandi melalui Supabase Auth.



Gambar 3.12 *Wireframe* Halaman *Login*

3. Halaman *Pemilihan Toko*

Memungkinkan pengguna yang telah *login* untuk memilih toko aktif yang akan dioperasikan, terutama bagi pengguna yang terdaftar di lebih dari satu outlet.



Gambar 3.13 *Wireframe* Halaman *Pemilihan Toko*

4. Halaman *Dasbor Owner*

Ringkasan performa toko yang menampilkan statistik penjualan harian, grafik tren omzet, pintasan fitur penting, dan akses cepat ke modul utama khusus

Owner.



Gambar 3.14 *Wireframe* Halaman Dasbor Owner

5. Halaman POS (Pembayaran)

Layar utama kasir untuk mencari produk, menyusun keranjang pesanan, menerapkan *voucher* diskon, memilih metode pembayaran, dan memproses transaksi.



Gambar 3.15 *Wireframe* Halaman POS (Pembayaran)

6. Halaman Riwayat Transaksi

Menampilkan daftar transaksi yang telah dilakukan lengkap dengan fitur pencarian dan *filter* berdasarkan tanggal, berguna untuk keperluan verifikasi dan audit oleh semua staf toko.



Gambar 3.16 *Wireframe* Halaman Riwayat Transaksi

7. Halaman Kelola Produk

Memungkinkan staf toko untuk menambah, menyunting, dan menghapus produk yang dijual, lengkap dengan harga, stok, *SKU/barcode*, gambar produk, dan kategori.



Gambar 3.17 *Wireframe* Halaman Kelola Produk

8. Halaman Kelola Kategori

Memungkinkan staf toko untuk membuat, mengedit, dan menghapus kategori produk guna mengorganisasi katalog dagangan toko dengan lebih terstruktur.



Gambar 3.18 *Wireframe* Halaman Kelola Kategori

9. Halaman Laporan

Layar yang dapat diakses seluruh staf toko untuk menampilkan laporan penjualan, tren bisnis, proyeksi penjualan harian berbasis model LSTM, dan ringkasan performa operasional toko.



Gambar 3.19 *Wireframe* Halaman Laporan

10. Halaman Pengaturan

Pusat konfigurasi aplikasi dan toko yang dapat diakses oleh semua staf, dengan sejumlah menu yang hanya tersedia bagi Owner seperti pengaturan profil toko dan integrasi pembayaran.



Gambar 3.20 *Wireframe* Halaman Pengaturan

11. Halaman Informasi Toko

Memungkinkan Owner untuk mengubah nama toko, alamat, logo outlet, dan informasi operasional lainnya yang ditampilkan kepada pelanggan.



Gambar 3.21 *Wireframe* Halaman Informasi Toko

12. Halaman Struk Digital

Menampilkan pratinjau struk transaksi dalam format digital yang dapat dibagikan kepada pelanggan, mencakup rincian produk, total pembayaran, dan informasi toko.



Gambar 3.22 *Wireframe* Halaman Struk Digital

13. Halaman Katalog Produk

Beranda mode pelanggan yang menampilkan katalog produk toko beserta kategori menu, informasi harga, dan fitur pencarian produk secara mandiri.



Gambar 3.23 *Wireframe* Halaman Katalog Produk

3.2.9 Teknik Pengujian

Pengujian sistem pada penelitian ini mencakup dua pendekatan utama untuk memastikan kualitas fungsional aplikasi dan keandalan model prediksi yang diintegrasikan. Pendekatan pengujian tersebut dibagi menjadi pengujian evaluasi model prediksi penjualan dan pengujian fungsionalitas sistem secara keseluruhan menggunakan metode *black box testing*.

3.2.9.1 Rancangan Pengujian Evaluasi Model Prediksi

Pengujian model prediksi dilakukan untuk mengukur kinerja dan tingkat akurasi dari algoritma *Long Short-Term Memory* (LSTM) yang dikembangkan. Pengujian ini menggunakan data pengujian (*testing data*) yang diambil dari data histori transaksi penjualan harian mitra UMKM. Evaluasi akurasi model diukur berdasarkan tingkat kesalahan (*error*) prediksi menggunakan empat metrik utama, yaitu MAE, RMSE, sMAPE, dan MASE, yang formula lengkapnya telah dijabarkan pada Subbab 2.6. Sebagai konvensi implementasi metrik sMAPE, apabila penyebut bernilai nol (nilai aktual dan prediksi sama-sama nol), penyebut diganti dengan nilai 1 agar tidak terjadi galat pembagian dengan nol (*division by zero*). Konvensi inilah yang diverifikasi pada pengujian *white box*.

Sebagai kriteria keberhasilan model pada diagram alur (Gambar 3.10), ditetapkan kriteria kelayakan yang bersifat **relatif terhadap baseline**, yaitu model dinyatakan layak apabila **MASE model** < **MASE baseline Naive** pada data uji yang sama. Kriteria relatif ini dipilih karena nilai MASE dinormalisasi terhadap galat naif satu langkah pada data latih (*in-sample*), sehingga nilai MASE > 1 pada data uji hanya menandakan bahwa periode uji lebih bergejolak dibandingkan periode latih, bukan berarti model secara otomatis lebih buruk daripada metode naif; perbandingan yang bermakna secara metodologis adalah antar metode pada data uji yang identik. Apabila kriteria tersebut belum terpenuhi, dilakukan iterasi penyetelan konfigurasi (*hyperparameter tuning*) meliputi jumlah neuron, *learning rate*, *batch size*, dan bentuk target prediksi. Pengujian evaluasi ini dilakukan

dengan mengukur kinerja model menggunakan pendekatan *multi-seed evaluation* (10 *seeds* acak) untuk memastikan stabilitas performa model LSTM terhadap variasi inisialisasi bobot awal jaringan saraf. Hasil pengujian akhir tersebut selanjutnya dibandingkan dengan model pembanding (*baselines*) untuk menentukan kelayakan model LSTM. Selain itu, diuji pula skenario perbandingan performa model LSTM yang dilatih dengan dan tanpa tambahan data sintetis hasil augmentasi TimeGAN terhadap *baseline Seasonal-Naive*, guna mengukur efektivitas augmentasi data dalam memitigasi keterbatasan ukuran dataset.

3.2.9.2 Rancangan Analisis Pengujian *Black Box*

Pengujian fungsional sistem pada penelitian ini menggunakan metode *black box testing*, yaitu metode pengujian perangkat lunak yang berfokus pada validasi fungsional sistem dengan mengamati kesesuaian antara masukan (*input*) dan keluaran (*output*) yang dihasilkan, tanpa memperhatikan struktur internal kode program. Pengujian diterapkan pada fitur-fitur utama sistem untuk memastikan aplikasi berjalan sesuai dengan kebutuhan operasional pengguna.

Rancangan skenario pengujian *black box* untuk fitur-fitur utama sistem POS ini dijabarkan pada Tabel 3.11 berikut:

Tabel 3.11 Skenario Pengujian *Black Box*

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
1	Registrasi Toko Baru	Mengisi <i>form</i> registrasi dengan email baru, kata sandi, nama toko, alamat, dan nomor HP.	Akun Owner berhasil dibuat, data toko tersimpan di <i>database</i> Supabase <i>cloud</i> , dan beralih ke halaman utama.

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
2	Login Akun	Memasukkan email dan kata sandi yang <i>valid/invalid</i> pada layar <i>login</i> .	Jika <i>valid</i> , pengguna masuk ke dasbor sesuai hak akses peran. Jika <i>invalid</i> , sistem menampilkan pesan <i>error</i> autentikasi.
3	Checkout Transaksi	Memasukkan produk ke keranjang, memilih metode bayar, dan mengonfirmasi nominal bayar.	Transaksi berhasil disimpan di <i>database</i> lokal Isar DB, jumlah stok produk berkurang otomatis, dan dialihkan ke struk sukses.
4	Terapkan Diskon	Memasukkan kode <i>voucher</i> /nilai diskon pada keranjang belanja sebelum pembayaran.	Total belanja terpotong sesuai nilai nominal diskon/ <i>voucher</i> dan tercatat pada rincian nota.
5	Mencetak Struk	Menghubungkan printer Bluetooth <i>thermal</i> dan menekan tombol cetak struk dari riwayat transaksi.	Printer <i>thermal</i> mencetak struk fisik transaksi secara lengkap (nama produk, total, tanggal, metode bayar).
6	Kelola Produk	Menambah produk baru dengan nama, harga, stok, foto, dan kategori serta mengubah/menghapus produk.	Data produk baru tersimpan di <i>database</i> lokal Isar DB, terdaftar pada <i>list</i> produk, dan dapat diubah/dihapus.
7	Kelola Kategori	Menambahkan kategori baru, menyunting nama kategori, atau menghapus kategori produk.	Kategori berhasil dibuat, muncul sebagai opsi <i>filter</i> menu, dan diperbarui secara <i>real-time</i> .
8	Audit Mutasi Stok	Melakukan transaksi/penyesuaian stok, lalu membuka halaman riwayat mutasi stok.	Riwayat keluar-masuk barang tercatat pada <i>log stock_history</i> dengan jenis mutasi yang sesuai.

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
9	Dasbor Ringkasan	Membuka dasbor laporan penjualan harian, mingguan, dan grafik visualisasi omzet.	Menampilkan statistik ringkasan omzet, total transaksi harian, dan grafik visualisasi garis yang akurat.
10	<i>Smart Analytics</i>	Membuka layar <i>Smart Analytics</i> dengan koneksi internet aktif.	Grafik prediksi penjualan 7 hari ke depan dari layanan API prediksi berhasil ditampilkan dan tersimpan sebagai <i>snapshot</i> .
11	<i>Broadcast Notifikasi</i>	Owner mengirim pesan <i>broadcast</i> kepada staf toko melalui menu notifikasi.	Notifikasi <i>broadcast</i> diterima dan muncul di perangkat kasir secara <i>real-time</i> .
12	Sinkronisasi <i>Offline</i>	Mematikan koneksi internet (luring), membuat transaksi lokal, lalu mengaktifkan internet kembali (daring).	Transaksi disimpan secara lokal di Isar DB (<i>offline-first</i>), lalu terunggah otomatis ke Supabase <i>cloud</i> saat internet aktif kembali.
13	Kelola Staf Karyawan	Owner menambahkan akun staf kasir baru dan mengubah peran staf.	Akun staf berhasil terdaftar pada toko dengan peran yang sesuai. Menu ini tidak dapat diakses oleh Kasir.
14	Atur Profil Toko	Owner mengubah nama, alamat, dan logo toko pada menu pengaturan.	Informasi profil toko berhasil diperbarui dan tampil pada struk serta katalog. Menu ini eksklusif untuk Owner.

3.2.9.3 Rancangan Analisis Pengujian *White Box*

Selain pengujian fungsional *black box*, penelitian ini turut menerapkan pengujian *white box* secara terbatas (*lightweight*) yang berfokus pada verifikasi kebenaran logika internal dan jalur eksekusi kode (*code path*) pada fungsi-fungsi

kritis di layanan API prediksi, tanpa memandang antarmuka luarnya. Pengujian ini dilakukan dengan menelusuri (*trace*) jalur logika kode secara manual menggunakan data masukan yang telah diketahui nilai keluarannya, kemudian membandingkan hasil eksekusi aktual terhadap hasil kalkulasi manual sebagai acuan kebenaran (*ground truth*). Tiga fungsi inti yang menjadi target pengujian *white box* adalah:

1. Fungsi perhitungan *Seasonal-Naive (by_dow)*, untuk memverifikasi jalur percabangan logika ketika jumlah data historis per hari kerja mencukupi ($\geq k$), tidak mencukupi ($< k$), maupun tidak tersedia sama sekali (*fallback*).
2. Fungsi metrik evaluasi sMAPE dan MASE, untuk memverifikasi jalur penanganan kasus pembagian dengan nilai penyebut nol atau mendekati nol agar tidak menghasilkan galat pembagian (*division by zero*).
3. Fungsi prediksi rekursif (*forecast_hybrid_stable*), untuk memverifikasi jalur eksekusi tiga mekanisme pengaman secara berurutan, yaitu *clipping log-return*, *damping factor*, dan *safety rail* nominal omzet.

3.2.10 Indikator Keberhasilan Penelitian

Keberhasilan penelitian ini diukur melalui indikator-indikator berikut, yang pencapaiannya dijawab pada Bab IV dan Bab V:

1. Aplikasi *Point of Sale (POS) mobile* berfungsi membantu pelaku UMKM dalam mengelola transaksi penjualan, inventaris produk, dan laporan keuangan secara efisien dengan kemampuan operasional *offline-first*, yang divalidasi melalui pengujian fungsional *Black Box*.

2. Metode LSTM terimplementasi pada sistem dan kinerjanya terukur secara objektif menggunakan metrik evaluasi kesalahan prediksi terhadap model pembandingan (*baseline*).
3. Sistem mampu menyajikan informasi prediksi dan laporan penjualan dalam bentuk visualisasi grafik yang mudah dipahami oleh pengguna, khususnya pelaku UMKM.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil rancang bangun dan pembahasan sistem Point of Sale (POS) dengan fitur prediksi penjualan harian menggunakan metode Long Short-Term Memory (LSTM). Pembahasan dibagi menjadi tujuh bagian utama, yaitu hasil implementasi sistem, *preprocessing* data, implementasi dan pelatihan model prediksi, evaluasi model, hasil pengujian sistem, pembahasan hasil penelitian, serta keterbatasan sistem dan penelitian.

Perlu ditegaskan di awal bahwa bab ini memaparkan dua hal yang berbeda namun saling terkait: (1) hasil eksperimen dan evaluasi metode LSTM sebagai objek kajian utama penelitian (Subbab 4.2 s.d. 4.4), dan (2) metode yang benar-benar disajikan oleh layanan API produksi (*endpoint* `/api/predict/daily`) yang dipanggil aplikasi *mobile* (Subbab 4.1.3 dan 4.5). Berdasarkan hasil evaluasi komparatif pada Subbab 4.4, LSTM belum terbukti unggul dibandingkan *baseline* statistik pada volume data penelitian ini, sehingga layanan produksi menerapkan *fallback* berbasis bukti berupa metode *Seasonal-Naive* ($k = 4$), sedangkan model LSTM (`.keras`) tetap didokumentasikan sebagai artefak riset. Arsitektur layanan prediksi bersifat *model-agnostic* sehingga dapat langsung menyajikan model LSTM begitu data mencukupi untuk mengungguli *baseline*. Selain itu, granularitas mingguan dan bulanan yang disebutkan pada Subbab 4.1.3 merupakan fitur pelengkap visualisasi pada antarmuka *Smart Analytics* dan berada di luar lingkup evaluasi ilmiah pada

bab ini, yang berfokus pada granularitas harian sesuai Batasan Masalah.

4.1 Hasil Implementasi Sistem

Bagian ini memaparkan realisasi fisik dari rancangan sistem yang telah disusun pada Bab III, yang mencakup implementasi antarmuka aplikasi mobile (kasir dan owner), implementasi backend dan basis data cloud (Supabase), serta implementasi layanan prediksi (API) di sisi server.

4.1.1 Implementasi Antarmuka (UI)

Aplikasi *mobile* dikembangkan menggunakan *framework* Flutter dengan bahasa pemrograman Dart, mengacu pada rancangan *wireframe* pada Subbab 3.2.8. Cuplikan hasil implementasi antarmuka diambil langsung dari aplikasi yang berjalan pada data toko mitra EatsTEDI, disusun berurutan mengikuti alur penggunaan aplikasi mulai dari registrasi akun, manajemen toko dan produk, transaksi kasir, hingga laporan analitik.

1. Halaman Registrasi

Halaman *Buat Akun* merupakan titik masuk awal bagi pengguna baru. Form registrasi memuat kolom Nama Lengkap, Email, *Password*, dan Konfirmasi *Password*, dilengkapi opsi pendaftaran cepat *Lanjutkan dengan Google* serta tautan menuju halaman Login bagi pengguna yang telah memiliki akun.



Gambar 4.1 Implementasi Halaman Registrasi

2. Halaman *Login*

Halaman *Selamat Datang Kembali* menyediakan autentikasi menggunakan Email dan *Password*, opsi *Ingat saya* dan *Lupa password*, serta tombol masuk melalui akun Google. Tombol *Masuk sebagai Pelanggan* disediakan sebagai jalur akses terpisah bagi pelanggan yang hendak memindai QR katalog mandiri tanpa memerlukan akun staf toko.



Gambar 4.2 Implementasi Halaman *Login*

3. Halaman Informasi Toko

Setelah registrasi, pengguna diarahkan ke halaman *Informasi Toko* untuk membuat outlet pertamanya, memuat kolom Nama Toko/*Outlet*, Provinsi dan Kota/Kabupaten (*dropdown* berjenjang), serta Alamat Lengkap, yang

kemudian dikonfirmasi melalui tombol *Konfirmasi & Mulai*.



Gambar 4.3 Implementasi Halaman Informasi Toko

4. Halaman Pilih Toko

Menampilkan daftar seluruh *outlet* yang terasosiasi dengan akun pengguna beserta peran pada masing-masing *outlet* (Owner atau Karyawan). Pengguna dapat bergabung ke *outlet* lain melalui *Kode Undangan* atau mendaftarkan *outlet* baru sebelum memilih toko aktif yang ingin dioperasikan.



Gambar 4.4 Implementasi Halaman Pilih Toko

5. Halaman Dasbor Owner

Menyajikan *Ringkasan Performa* toko dengan *filter* rentang waktu (Hari Ini, Minggu Ini, Bulan Ini), empat kartu statistik *real-time* (Omzet, Transaksi, Stok Rendah, dan Produk Aktif), serta grafik *Performa Penjualan* yang memvisualisasikan tren omzet tujuh hari terakhir. Navigasi bawah aplikasi

(Dasbor, Kasir, Riwayat, Laporan, dan menu lainnya) juga tampak pada halaman ini.



Gambar 4.5 Implementasi Halaman Dasbor Owner

6. Halaman Kelola Produk dan Tambah Produk

Halaman *Katalog Produk* menampilkan daftar inventaris beserta foto, kategori, status stok, harga, dan kode SKU, dilengkapi kolom pencarian dan *filter* kategori (Semua, Minuman, Makanan). Formulir *Tambah Produk* memuat unggah foto produk, nama, kategori, SKU/*Barcode* (dapat dipindai atau digenerasi otomatis), harga modal, harga jual, dan stok awal.



(a) Katalog Produk



(b) Tambah Produk

Gambar 4.6 Implementasi Halaman Kelola Produk dan Tambah Produk

7. Halaman Kelola Kategori

Menyediakan pengelompokan produk melalui kategori yang dapat ditambah,

disunting, dan dihapus, dilengkapi pencarian kategori dan penghitung jumlah produk pada setiap kategori (misalnya Minuman dan Makanan).



Gambar 4.7 Implementasi Halaman Kelola Kategori

8. Halaman Kelola Stok dan Ubah Stok Produk

Halaman *Kelola Stok* menampilkan daftar produk beserta harga dan jumlah stok terkini, dengan tombol *Ubah* pada setiap baris. Menekan tombol tersebut memunculkan modal *Ubah Stok Produk* berisi *stepper* penambahan/pengurangan stok manual serta pilihan pintasan (-10, -5, +5, +10) sebelum disimpan.



(a) Kelola Stok



(b) Modal Ubah Stok Produk

Gambar 4.8 Implementasi Halaman Kelola Stok dan Ubah Stok Produk

9. Halaman Riwayat Stok

Berfungsi sebagai log audit mutasi stok, menampilkan jenis mutasi

(Penjualan atau Penyesuaian Manual), perubahan jumlah stok sebelum dan sesudah (misalnya dari 41 menjadi 40 *pcs*), staf yang melakukan perubahan, serta waktu kejadian, dilengkapi *filter* berdasarkan jenis mutasi.



Gambar 4.9 Implementasi Halaman Riwayat Stok

10. Halaman Kasir (POS) dan Detail Pesanan

Merupakan layar operasional utama kasir, menampilkan katalog produk dalam bentuk *grid* dengan pencarian dan pemindaian *barcode*. Memilih produk memunculkan modal *Detail Pesanan* yang merinci nama item, harga satuan, kuantitas melalui *stepper*, subtotal, dan total bayar sebelum dilanjutkan ke pembayaran.



(a) Kasir (POS)



(b) Detail Pesanan

Gambar 4.10 Implementasi Halaman Kasir (POS) dan Detail Pesanan

11. Halaman Pembayaran

Menampilkan total tagihan, pilihan metode pembayaran (Tunai atau QRIS), kolom *Uang Tunai Diterima* beserta pintasan nominal pecahan umum (Rp25rb, Rp50rb, Rp100rb), dan kalkulasi kembalian otomatis sebelum transaksi dikonfirmasi dan disimpan.



Gambar 4.11 Implementasi Halaman Pembayaran

12. Halaman Riwayat Transaksi

Menampilkan ringkasan kumulatif Omzet dan jumlah Transaksi, *filter* periode (Semua, Hari Ini, Kemarin, Pilih Tanggal) serta status (Berhasil, *Pending*, Batal), dan daftar transaksi yang dikelompokkan per tanggal lengkap dengan nomor invoice, jam, metode bayar, dan nominal.



Gambar 4.12 Implementasi Halaman Riwayat Transaksi

13. Halaman Struk Digital

Menampilkan rincian nomor transaksi, tanggal, metode pembayaran, nama kasir, total belanja, dan kembalian, dilengkapi kode QR yang dapat dipindai pelanggan untuk melihat struk secara *online*, serta tombol *Bagikan* dan *Set Printer* untuk mencetak struk fisik.



Gambar 4.13 Implementasi Halaman Struk Digital

14. Halaman Laporan Analitik

Menyajikan ringkasan Omzet dan Transaksi Keseluruhan, jumlah Stok Rendah dan Produk Aktif, serta grafik *Tren Penjualan* bulanan yang memvisualisasikan riwayat omzet toko EatsTEDI sejak Agustus 2024 hingga Juni 2026, sejalan dengan rentang data penelitian pada Subbab 3.1.5. Kartu *Smart Analitik* pada bagian atas halaman menjadi pintu masuk menuju fitur prediksi berbasis AI.



(a) Ringkasan Laporan




(b) Grafik Tren Penjualan Bulanan

Gambar 4.14 Implementasi Halaman Laporan Analitik

15. Halaman *Smart Analitik* dan Riwayat Analisis

Halaman *Smart Analitik* memanggil layanan prediksi yang di-*deploy* pada *HuggingFace Space (Cloud)* dengan estimasi lokal *on-device* sebagai jalur cadangan apabila layanan *cloud* tidak dapat dijangkau, konsisten dengan strategi *offline-first* yang dibahas pada Subbab 3.2.1. Ketika riwayat transaksi toko masih kurang dari batas minimum sekuens LOOK_BACK yang disyaratkan model (lihat Subbab 3.2.7), sistem menampilkan peringatan *cold start* dan menyajikan estimasi berbasis pola bisnis retail/kafe umum sebagai gantinya. Halaman ini menampilkan kartu Estimasi Omzet dan Estimasi *Traffic*, grafik *Forecasting* yang membedakan data riil dengan hasil prediksi AI, serta proyeksi menu terlaris untuk hari berikutnya. Setiap analisis yang dijalankan turut dicatat pada halaman *Riwayat Analisis* beserta sumber komputasi (*Cloud* atau Lokal) dan estimasi omzet yang dihasilkan.

Gambar 4.15 Implementasi Halaman *Smart Analitik*

Gambar 4.16 Implementasi Halaman Riwayat Analisis

4.1.2 Implementasi Backend dan Basis Data Cloud

Infrastruktur backend cloud diimplementasikan menggunakan platform Supabase BaaS dengan database PostgreSQL. Struktur relasional database diwujudkan melalui sembilan tabel utama yang saling terhubung:

1. *stores*: Menyimpan data identitas outlet merchant (id, nama, alamat, nomor HP, URL logo, created_at).
2. *store_members*: Mengatur relasi hak akses pengguna dengan peran Owner atau Karyawan di masing-masing outlet.
3. *categories*: Mengelola daftar kategori pengelompokan produk.

4. *products*: Menyimpan katalog inventaris barang (id, nama, harga, stok, barcode, URL foto, is_synced, is_deleted).
5. *transactions*: Menyimpan data nota induk transaksi penjualan (id, total belanja, metode pembayaran, kasir_id, created_at).
6. *transaction_items*: Menyimpan rincian item produk yang terjual pada setiap transaksi penjualan (id, transaksi_id, produk_id, jumlah, harga).
7. *stock_history*: Mencatat log audit mutasi perubahan stok produk (stok masuk, keluar, penjualan, audit manual).
8. *notifications*: Mengelola pesan notifikasi sistem dan info siaran antar staf toko secara real-time.
9. *smart_analytics_snapshots*: Menyimpan riwayat *snapshot* hasil analitik prediksi LSTM setiap kali fitur *Smart Analytics* dijalankan, sehingga hasil analisis sebelumnya dapat ditinjau kembali tanpa memanggil ulang model.

Keamanan akses data antar-outlet dijamin melalui penerapan kebijakan Row Level Security (RLS) di database PostgreSQL. Kebijakan ini memastikan bahwa pengguna (kasir/owner) hanya dapat membaca dan menulis data yang memiliki *store_id* yang sesuai dengan toko tempat mereka terdaftar.

4.1.3 Implementasi Layanan Prediksi (API)

Modul kecerdasan buatan untuk kalkulasi prediksi penjualan harian dikembangkan menggunakan Python dan terdiri atas dua bagian yang saling melengkapi. Bagian pertama adalah *pipeline* riset berbasis Jupyter Notebook yang melatih model prediksi LSTM (TensorFlow/Keras) pada tiga granularitas waktu

(harian, mingguan, dan bulanan) beserta eksperimen augmentasi data sintetis TimeGAN (PyTorch). Bagian kedua adalah layanan API produksi berbasis *framework* Flask yang di-*deploy* pada platform Hugging Face dan diintegrasikan langsung dengan aplikasi POS, sehingga beban komputasi prediksi terpisah dari beban kerja transaksional kasir.

Layanan API produksi menyediakan tujuh *endpoint* REST dengan fungsi sebagai berikut:

1. **Endpoint Prediksi Penjualan** (*/api/predict/daily*, */api/predict/weekly*, */api/predict/monthly*): Meramalkan omzet ke depan dengan tanggal prediksi yang otomatis melewati hari tutup (akhir pekan serta libur semester Januari/Juli). Berdasarkan hasil evaluasi komparatif pada penelitian ini (Subbab 4.4), metode penyaji yang dipilih pada *endpoint* produksi adalah metode statistik paling stabil, yaitu *Seasonal-Naive* ($k = 4$, rata-rata empat kemunculan terakhir hari yang sama, kompromi antara responsivitas terhadap tren terbaru dan peredaman fluktuasi acak, setara dengan rentang sekitar satu bulan hari sejenis) untuk harian, *Mean-4* untuk mingguan, dan *Mean-3* untuk bulanan, dengan prediksi *Naive* disertakan sebagai pembandingan, sedangkan model LSTM hasil pelatihan didokumentasikan sebagai artefak riset (*.keras*).
2. **Endpoint Rekomendasi Operasional** (*/api/recommendations/stock* dan */api/recommendations/target*): Menghasilkan rekomendasi alokasi anggaran belanja per kategori produk dan kuantitas stok produk teratas berdasarkan

proyeksi omzet (dilengkapi *safety buffer* 15% dan peringatan khusus produk mudah basi), serta tiga tingkatan target omzet harian (konservatif, moderat, dan agresif) berbasis statistik 15 hari aktif terakhir.

3. **Endpoint Pencatatan dan Status** (*/api/sales/record* dan */api/status*):

Menerima rekap penjualan harian dari aplikasi POS dan memperbaruinya ke dataset historis (*upsert* per tanggal) agar dasar prediksi selalu mengikuti data terkini, serta memeriksa kesehatan layanan dan ketersediaan berkas data.

Aplikasi Flutter memanggil *endpoint* tersebut secara langsung melalui HTTPS dengan *payload* agregat penjualan tanpa informasi identitas pelanggan, kemudian menyimpan hasil analisis sebagai *snapshot* pada tabel *smart_analytics_snapshots* di Supabase.

Inti implementasi *endpoint* prediksi harian pada berkas *app.py* disajikan pada Kode Program IV.1 (dipersingkat). Metode *Seasonal-Naive* dihitung dengan merata-ratakan *k* kemunculan terakhir dari setiap hari kerja yang sama, dan tanggal prediksi dihasilkan dengan melewati hari tutup.

```

1 @app.route('/api/predict/daily', methods=['GET', 'POST'])
2 def predict_daily():
3     data = request.get_json(silent=True) or {}
4     n_days = int(data.get("n_days", 7))
5     k = int(data.get("k", 4))
6     dfa = get_daily_dataframe(data.get("history", None))
7     last_date = dfa['date'].max()
8
9     # Seasonal-Naive: rata-rata k kemunculan terakhir

```

```

10     # dari hari kerja yang sama (0=Senin ... 4=Jumat)
11     by_dow = {}
12     for dow in range(5):
13         dow_data = dfa[dfa['day_of_week'] == dow]['revenue']
14         if len(dow_data) >= k:
15             by_dow[dow] = dow_data.tail(k).mean()
16         elif len(dow_data) > 0:
17             by_dow[dow] = dow_data.mean()
18         else:
19             by_dow[dow] = dfa['revenue'].tail(10).mean()
20
21     # Naive: prediksi = omzet hari kerja terakhir
22     naive_value = float(dfa['revenue'].iloc[-1])
23
24     # Tanggal prediksi otomatis melewati hari tutup
25     future_dates = generate_future_business_days(last_date,
26                                                    n_days)
27     predictions = []
28     for dt in future_dates:
29         pred_sn = int(round(by_dow.get(dt.weekday(),
30                                     naive_value)))
31         predictions.append({
32             "date": dt.strftime('%Y-%m-%d'),
33             "predicted_revenue_seasonal_naive": pred_sn,
34             "predicted_revenue_naive":
35                 int(round(naive_value)))
36     return jsonify({"predictions": predictions}), 200

```

Kode Program IV.1: Implementasi Endpoint Prediksi Harian Seasonal-Naive (*app.py*)

4.2 Preprocessing Data

Bagian ini menjelaskan tahapan pengolahan data sebelum digunakan untuk melatih model prediksi, mencakup deskripsi dan eksplorasi awal dataset, serta pra-pemrosesan dan pembentukan sequence data latih.

4.2.1 Deskripsi Data dan Eksplorasi Awal

Data yang digunakan dalam pengujian model prediksi ini merupakan rekapitulasi transaksi penjualan harian kantin EatsTEDi UGM pada periode 26 Agustus 2024 hingga 20 Juni 2026. Setelah dilakukan agregasi nilai transaksi per hari dan penyaringan terhadap hari-hari non-aktif (di mana kantin tutup), diperoleh total sebanyak 313 hari aktif bisnis. Statistik ringkas mengenai dataset pendapatan harian ini disajikan pada Tabel 4.1.

Tabel 4.1 Statistik Ringkas Dataset Pendapatan Harian

Karakteristik	Nilai
Jumlah hari aktif	313 hari
Rentang waktu	26 Agu 2024 – 20 Jun 2026
Total revenue (omzet)	Rp 471.200.494,00
Rata-rata revenue per hari aktif	Rp 1.505.433,00
Revenue tertinggi	Rp 3.738.500,00 (6 Mei 2026)

Hasil eksplorasi awal menunjukkan bahwa deret data pendapatan harian kantin EatsTEDi bersifat sangat fluktuatif dan dipengaruhi secara kuat oleh

kalender akademis universitas. Terdapat pola penurunan tajam hingga bernilai Rp 0 pada masa libur semester mahasiswa (sepanjang bulan Januari dan Juli) serta pola musiman mingguan di mana penjualan menurun secara bertahap menjelang akhir pekan. Pola musiman tahunan tidak dapat teramati secara penuh karena rentang waktu data yang tersedia kurang dari dua tahun, sehingga deret waktu ini tergolong pendek (*short time-series*) untuk standar pemodelan berbasis *deep learning* yang membutuhkan volume data historis yang besar.

4.2.2 Pra-pemrosesan dan Pembentukan Sequence

Pemodelan prediksi pada penelitian ini difokuskan pada granularitas harian dengan strategi prediksi satu langkah ke depan (*one-step-ahead prediction*). Untuk mengatasi variansi data yang ekstrem akibat fluktuasi harian yang sangat tajam, target prediksi tidak diprediksi menggunakan bentuk nilai nominal mentah, melainkan menggunakan bentuk *log-return* (selisih logaritmik) pendapatan antar hari aktif yang berurutan. Pendekatan residual ini dirancang agar model cukup mempelajari koreksi atau deviasi nilai pendapatan dari hari aktif sebelumnya, sehingga model secara tidak langsung mewarisi sifat autokorelasi jangka pendek yang kuat pada deret waktu transaksi.

Variabel masukan (*features*) terdiri atas nilai *log-return* pendapatan target dan enam fitur kalender yang dikodekan secara siklik (*cyclical encoding* sinus-kosinus untuk nomor minggu dalam setahun, bulan, dan hari kerja aktif) serta variabel biner Ramadan. Variabel jumlah transaksi harian dan kuantitas produk terjual secara sengaja dikeluarkan dari variabel masukan model prediksi

untuk menghindari kebocoran data (*data leakage*), karena kedua nilai tersebut belum tersedia saat modul prediksi dijalankan untuk memprediksi hari berikutnya. Proses penskalaan data dilakukan menggunakan metode *Min-Max Scaling* yang dipasang (*fit*) hanya pada data latih untuk mencegah terjadinya kebocoran informasi dari data uji.

Pembagian dataset dilakukan secara kronologis (*chronological split*) dengan rasio 70% untuk data latih (*train set*), 15% untuk data validasi (*validation set*), dan 15% untuk data uji (*test set*). Pembentukan urutan temporal (*sequence*) dilakukan menggunakan panjang *look-back* sebesar 7 hari aktif terakhir. Rincian pembagian data serta dimensi sequence disajikan pada Tabel 4.2.

Tabel 4.2 Pembagian Dataset dan Dimensi Sequence

Subset Data	Jumlah Hari	Jumlah Sequence	Dimensi Masukan
Latih (<i>train</i>)	219	212	(212, 7, 8)
Validasi (<i>val</i>)	46	39	(39, 7, 8)
Uji (<i>test</i>)	48	41	(41, 7, 8)

Implementasi pra-pemrosesan data, meliputi penyaringan hari aktif, transformasi target *log-return*, dan pengodean siklik fitur kalender, disajikan pada Kode Program IV.2.

```

1 df = pd.read_csv(DAILY_CSV, parse_dates=['date'])
2 # Hanya hari aktif (revenue > 0) yang dilatih ke model
3 dfa = df[df['revenue'] > 0].copy() \
4     .sort_values('date').reset_index(drop=True)
5
6 dfa['rev_log'] = np.log1p(dfa['revenue'])

```

```

7  # TARGET: log-return (perubahan pendapatan harian)
8  dfa['logret'] = dfa['rev_log'].diff().fillna(0.0)
9  # Pengodean siklik sinus-kosinus fitur kalender
10 dfa['week_sin'] = np.sin(2*np.pi*dfa['week_of_year']/52)
11 dfa['week_cos'] = np.cos(2*np.pi*dfa['week_of_year']/52)
12 dfa['month_sin'] = np.sin(2*np.pi*dfa['month']/12)
13 dfa['month_cos'] = np.cos(2*np.pi*dfa['month']/12)
14 dfa['dow_sin'] = np.sin(2*np.pi*dfa['day_of_week']/5)
15 dfa['dow_cos'] = np.cos(2*np.pi*dfa['day_of_week']/5)
16
17 # 'logret' wajib kolom pertama (kolom target)
18 FEATURES = ['logret', 'week_sin', 'week_cos', 'month_sin',
19             'month_cos', 'dow_sin', 'dow_cos', 'is_ramadan']
20
21 # Pembagian kronologis 70/15/15 (tanpa pengacakan)
22 n = len(dfa); n_tr = int(n*0.70); n_va = int(n*0.15)
23 df_tr = dfa.iloc[:n_tr]
24 df_va = dfa.iloc[n_tr:n_tr+n_va]
25 df_te = dfa.iloc[n_tr+n_va:]

```

Kode Program IV.2: Pra-pemrosesan Data: Filter Hari Aktif, Log-Return, dan Fitur Siklik

4.3 Implementasi dan Pelatihan Model Prediksi

Bagian ini memaparkan implementasi arsitektur model LSTM beserta skenario eksperimen, hasil pelatihan model, implementasi augmentasi data sintetis TimeGAN, dan implementasi mekanisme prediksi rekursif untuk kebutuhan

visualisasi jangka pendek pada aplikasi.

4.3.1 Arsitektur Model dan Skenario Eksperimen

Arsitektur model prediksi yang diimplementasikan adalah LSTM satu lapis (*single-layer LSTM*) dengan 24 *hidden units*, diikuti oleh lapisan *Dropout* dengan laju 0,1 untuk regularisasi, satu lapisan *Dense* dengan 16 neuron beraktivasi *Rectified Linear Unit* (ReLU), dan diakhiri oleh satu lapisan keluaran (*output layer*) tunggal beraktivasi linear. Model ini dirancang secara minimalis dengan total parameter terlatih hanya sebanyak 3.585 parameter. Pemilihan model berkapasitas rendah ini didasarkan pada jumlah data latih yang sangat terbatas (212 sampel sequence), sehingga penggunaan model LSTM berkapasitas besar (*stacked layers*) akan berisiko tinggi memicu kegagalan konvergensi pelatihan atau bias *overfitting*. Proses optimasi menggunakan metode Adam dengan *learning rate* awal sebesar 5×10^{-4} , fungsi kerugian (*loss function*) MSE, serta didukung *callbacks EarlyStopping* dan *ReduceLROnPlateau*. Konstruksi arsitektur model beserta konfigurasi pelatihannya disajikan pada Kode Program IV.3.

```

1 LOOK_BACK = 7    # jendela masukan: 7 hari aktif
2 HORIZON    = 1    # prediksi 1 langkah ke depan
3 UNITS      = 24
4 DROPOUT    = 0.1
5
6 def build_lstm():
7     m = Sequential([
8         LSTM(UNITS, input_shape=(LOOK_BACK, len(FEATURES))),

```

```

9         Dropout(DROPOUT),
10        Dense(16, activation='relu'),
11        Dense(HORIZON)
12    ], name='lstm_hybrid_residual')
13    m.compile(optimizer=Adam(5e-4), loss='mse',
14              metrics=['mae'])
15
16    return m
17
18    cb = [EarlyStopping('val_loss', patience=20,
19                      restore_best_weights=True),
20          ReduceLROnPlateau('val_loss', factor=0.5,
21                            patience=8, min_lr=1e-6)]
22
23    model = build_lstm()
24    hist = model.fit(X_tr, y_tr, validation_data=(X_va, y_va),
25                    epochs=200, batch_size=16, callbacks=cb)

```

Kode Program IV.3: Konstruksi Arsitektur LSTM Tersederhanakan dan Konfigurasi Pelatihan

4.3.2 Hasil Pelatihan Model

Pada konfigurasi akhir model tersederhanakan, proses pelatihan berjalan secara stabil di mana galat validasi menunjukkan tren penurunan yang konsisten melampaui *epoch* pertama. Mekanisme *EarlyStopping* berhasil menghentikan proses pelatihan dan mengembalikan bobot terbaik model sebelum terjadi gejala *overfitting*. Hal ini berbanding terbalik dengan uji coba pada konfigurasi awal

penelitian yang menggunakan arsitektur jaringan saraf berskala besar dan target berupa nilai nominal mentah, di mana model mengalami kolaps (*model collapse*) dengan galat validasi terbaik yang dicapai langsung pada *epoch* pertama (model tidak melakukan pembelajaran) dan menghasilkan prediksi bernilai rendah yang konstan secara sistematis. Penyederhanaan arsitektur, pemilihan target *log-return*, serta pembatasan horizon menjadi satu langkah ke depan terbukti mampu memperbaiki performa pelatihan secara signifikan, di mana nilai MAE uji terbaik model LSTM mengalami penurunan drastis dari sekitar Rp 1.805.196,00 pada konfigurasi awal menjadi berkisar antara Rp 500.000,00 hingga Rp 600.000,00 pada konfigurasi akhir. Iterasi dari konfigurasi awal (arsitektur besar, target nominal) menuju konfigurasi akhir tersederhanakan inilah yang merupakan realisasi dari *loop hyperparameter tuning* dengan kriteria akurasi ($MASE < 1$) pada diagram alur Gambar 3.10. Meskipun kriteria $MASE < 1$ pada akhirnya tidak tercapai oleh konfigurasi manapun, iterasi dihentikan pada konfigurasi terbaik dan keputusan produksi dialihkan ke metode *baseline* sebagaimana dibahas pada Subbab 4.4. Grafik kurva kerugian pelatihan model ditunjukkan pada Gambar 4.17.



Gambar 4.17 Kurva Kerugian Pelatihan (*Training Loss Curve*) Model LSTM

4.3.3 Implementasi Augmentasi Data Sintetis TimeGAN

Sebagai upaya mitigasi terhadap keterbatasan ukuran dataset yang menjadi akar penyebab ketidakstabilan model LSTM, dilakukan eksperimen augmentasi data sintetis menggunakan **TimeGAN** (Yoon et al., 2019). Model TimeGAN yang diimplementasikan dengan PyTorch dilatih pada jendela deret waktu sepanjang 24 hari aktif dengan tiga fitur numerik (omzet, jumlah transaksi, dan kuantitas terjual) melalui tiga fase pelatihan (*autoencoder*, *supervised*, dan *joint adversarial training*) masing-masing sebanyak 600 *epoch*, kemudian menghasilkan 298 sekuens data harian sintetis dari 199 sekuens data riil (rasio augmentasi 1,5). Pada skenario ini, model LSTM multi-langkah (*look-back* 14 hari aktif, horizon 7 hari) selanjutnya dilatih dalam dua kondisi: hanya menggunakan 199 sekuens data riil (*baseline real-only*), dan menggunakan gabungan data riil dengan 298 sekuens sintetis (rasio augmentasi 1,5). Hasil evaluasi perbandingan kedua kondisi tersebut

disajikan pada Subbab 4.4.3.

Cuplikan implementasi dua dari lima jaringan penyusun TimeGAN pada berkas *TimeGAN.py*, yaitu jaringan *embedder* yang memetakan data riil ke ruang laten dan *generator* yang memetakan derau acak menjadi representasi laten sintetis, disajikan pada Kode Program IV.4.

```

1  class EmbedderNet(nn.Module):
2      """Memetakan data nyata X -> representasi laten H."""
3      def __init__(self):
4          super().__init__()
5          self.rnn = nn.GRU(NUM_FEAT, HIDDEN_DIM,
6                             NUM_LAYERS, batch_first=True)
7          self.proj = nn.Sequential(
8              nn.Linear(HIDDEN_DIM, HIDDEN_DIM), nn.Sigmoid())
9
10     def forward(self, x):
11         h, _ = self.rnn(x)
12         return self.proj(h)
13
14 class GeneratorNet(nn.Module):
15     """Memetakan noise Z -> laten sintetis E."""
16     def __init__(self):
17         super().__init__()
18         self.rnn = nn.GRU(NUM_FEAT, HIDDEN_DIM,
19                            NUM_LAYERS, batch_first=True)
20         self.proj = nn.Sequential(
21             nn.Linear(HIDDEN_DIM, HIDDEN_DIM), nn.Sigmoid())

```

```

22
23     def forward(self, z):
24         h, _ = self.rnn(z)
25         return self.proj(h)
26
27 # Tiga fase pelatihan (masing-masing 600 epoch):
28 # 1) train_embedder : autoencoder embedder-recovery
29 # 2) train_supervisor: dinamika temporal ruang laten
30 # 3) train_joint      : pelatihan gabungan adversarial

```

Kode Program IV.4: Implementasi Jaringan *Embedder* dan *Generator* TimeGAN

(PyTorch)

4.3.4 Implementasi Prediksi Rekursif ke Depan

Untuk kebutuhan penyajian visualisasi ramalan penjualan harian selama 7 hari aktif ke depan secara rekursif (*recursive forecasting*), model LSTM residual yang melakukan iterasi mandiri mengalami kerentanan berupa penumpukan kesalahan (*error propagation*) di mana nilai prediksi meluruh secara eksponensial hingga bernilai sangat kecil dan tidak realistis. Setelah ditambahkan mekanisme pengaman berupa *clipping* pada *log-return* (dijepit antara persentil 10–90 data latih), *damping factor* ($\phi = 0.7$) untuk meredam perubahan pada horizon yang jauh, serta *safety rail* penahan nominal omzet harian aktif, grafik prediksi yang dihasilkan menjadi lebih stabil dan realistis. Implementasi inti dari fungsi prediksi rekursif beserta ketiga mekanisme pengaman tersebut disajikan pada Kode

Program IV.5.

```

1  # Batas clip dari persentil 10-90 log-return data latih
2  LR_LO, LR_HI = np.percentile(_train_logret, [10, 90])
3  REV_FLOOR = np.percentile(_act_rev, 2)    # rail bawah
4  REV_CEIL  = _act_rev.max()                # rail atas
5
6  def forecast_hybrid_stable(model, dfa, scaler, features,
7                             look_back, n_steps, phi=0.7):
8      window = scaler.transform(
9          dfa.tail(look_back)[features].values)
10     prev_rev = float(dfa['revenue'].iloc[-1])
11     d, step, rows = pd.Timestamp(dfa['date'].max()), 0, []
12     while len(rows) < n_steps:
13         d += pd.Timedelta(days=1)
14         # Lewati hari tutup (akhir pekan, Januari & Juli)
15         if d.weekday() >= 5 or d.month in [1, 7]:
16             continue
17         step += 1
18         raw_lr = float(inv_logret(
19             model.predict(window[np.newaxis])[0, 0]))
20         lr_clip = float(np.clip(raw_lr, LR_LO, LR_HI)) # 1)
21         clip
22         lr_damp = lr_clip * (phi ** (step - 1)) # 2)
23         damp
24         rev = float(np.expml(np.loglp(prev_rev) + lr_damp))
25         rev = float(np.clip(rev, REV_FLOOR, REV_CEIL)) # 3)
26         rail

```

```

24         # Susun baris fitur baru utk tanggal d (dipersingkat)
25         raw = build_feature_row(d, raw_lr)
26         # Geser jendela masukan dengan baris fitur baru
27         window = np.vstack([window[1:],
28                             scaler.transform([raw])[0]])
29         prev_rev = rev
30         rows.append({'tanggal': d.date(),
31                     'prediksi_revenue': int(round(rev))})
32     return pd.DataFrame(rows)

```

Kode Program IV.5: Prediksi Rekursif dengan *Clipping*, *Damping*, dan *Safety Rail*

Secara statistik, prediksi rekursif jangka panjang berbasis LSTM pada data terbatas ini akan dengan cepat meredam menuju nilai rata-rata historis (sifat *mean-reverting*) dan menyerupai prediksi naif. Untuk diintegrasikan ke dalam fitur aplikasi riil kasir, metode prediksi statistik *SARIMA* dan *Seasonal-Naive* (rata-rata hari sejenis pada minggu sebelumnya) lebih direkomendasikan karena memberikan hasil prediksi multi-langkah yang jauh lebih stabil dan konsisten. Rekomendasi ini diwujudkan pada layanan API produksi, di mana *endpoint* prediksi menyajikan metode *Seasonal-Naive* ($k = 4$) sebagai metode penyaji utama prediksi harian kepada aplikasi POS. Dalam penelitian skripsi ini, hasil evaluasi akurasi ilmiah tetap didasarkan pada pengujian satu langkah ke depan (*one-step-ahead*), sedangkan visualisasi prediksi multi-langkah diposisikan murni sebagai ilustrasi fungsionalitas sistem.

Pengukuran akurasi model dilakukan menggunakan empat metrik evaluasi secara simultan, yaitu MAE, RMSE, sMAPE, dan MASE. Penggunaan MAPE konvensional dihindari karena karakteristik dataset transaksi memiliki beberapa hari aktif dengan nilai nominal pendapatan yang sangat rendah (mendekati nol), sehingga pembagian terhadap nilai aktual tersebut akan menyebabkan pembagian dengan nol atau nilai persentase galat yang sangat besar (*exploding MAPE*) yang tidak representatif. Metrik MASE dipilih sebagai acuan performa utama karena ternormalisasi terhadap galat prediksi naif secara *in-sample*, di mana nilai MASE kurang dari satu menandakan bahwa kinerja model prediksi lebih baik dibandingkan model naif sederhana. Sebagai model pembanding (*baselines*) pada skema satu langkah ke depan, digunakan tiga metode pembanding statistik sederhana: (1) *Naive* (kemarin) di mana prediksi hari ini disamakan dengan realisasi hari kemarin, (2) *Mean-7* berupa rata-rata bergerak dari 7 hari aktif terakhir, dan (3) model statistik *SARIMA* dengan skema prediksi *rolling one-step*. Implementasi fungsi metrik evaluasi sMAPE dan MASE yang digunakan pada seluruh pengujian disajikan pada Kode Program IV.6.

```
1 def smape(y, yhat):
2     # sMAPE: galat dibagi rata-rata |aktual| dan |prediksi|
3     d = (np.abs(y) + np.abs(yhat)) / 2
4     return np.mean(np.abs(y - yhat)
5                     / np.where(d == 0, 1, d)) * 100
6
```

```

7 def mase(y, yhat, naive_mae):
8     # MASE: galat dinormalisasi thd galat naif in-sample
9     return mean_absolute_error(y, yhat) / naive_mae
10
11 def report(y, yhat, naive_mae, label):
12     rmse = np.sqrt(mean_squared_error(y, yhat))
13     mae = mean_absolute_error(y, yhat)
14     return {'rmse': rmse, 'mae': mae,
15            'smape': smape(y, yhat),
16            'mase': mase(y, yhat, naive_mae)}

```

Kode Program IV.6: Implementasi Fungsi Metrik Evaluasi sMAPE dan MASE

4.4.1 Evaluasi Model dan Perbandingan dengan Baseline

Setelah pelatihan diselesaikan, dilakukan evaluasi performa model prediksi pada dataset uji (*testing data*). Hasil evaluasi performa model LSTM Hybrid dibandingkan dengan ketiga metode pembanding (*baselines*) disajikan pada Tabel 4.3. Nilai performa LSTM Hybrid yang disajikan pada tabel merupakan nilai rata-rata dari sepuluh kali percobaan dengan inisialisasi bobot acak yang berbeda (*multi-seed*).

Tabel 4.3 Perbandingan Performa pada Data Uji (*One-Step-Ahead*)

Model	MAE (Rp)	RMSE (Rp)	sMAPE	MASE
Naive (kemarin)	519.841	697.253	30,77%	1,432
SARIMA	586.083	751.408	33,80%	1,615
Mean-7	647.263	791.746	36,25%	1,784
LSTM Hybrid (Rata-rata)	667.718	897.563	38,06%	1,840

Berdasarkan hasil perbandingan pada Tabel 4.3, secara rata-rata metode *Naive* sederhana memberikan kesalahan prediksi terkecil dengan MAE sebesar Rp 519.841,00, disusul oleh model statistik *SARIMA* dan *Mean-7*. Model LSTM Hybrid berada di posisi terakhir dengan nilai MAE rata-rata sebesar Rp 667.718,00 dan MASE sebesar 1,840. Temuan ini mengindikasikan karakteristik data pendapatan kantin EatsTEDI UGM yang didominasi oleh persistensi jangka pendek yang kuat (omzet hari ini sangat dekat dengan omzet kemarin). Karakteristik persistensi ini dapat ditangkap secara sangat efisien oleh model naif, sementara model LSTM Hybrid yang dilatih menggunakan ukuran data yang relatif kecil mengalami *over-smoothing* (penghalusan berlebih) sehingga kurang mampu menangkap lonjakan-lonjakan pendapatan harian secara presisi. Perlu dicatat bahwa seluruh metode pada Tabel 4.3 – termasuk *Naive* itu sendiri – memiliki nilai MASE lebih besar dari satu (1,432 hingga 1,840). Hal ini terjadi karena MASE dinormalisasi terhadap galat naif satu langkah *in-sample* yang dihitung pada data latih, sehingga nilai $MASE > 1$ pada data uji semata menandakan bahwa periode uji secara umum lebih bergejolak (memiliki variansi/perubahan harian yang lebih besar) dibandingkan periode latih yang menjadi acuan normalisasi, bukan berarti seluruh metode gagal secara mutlak. Oleh karena itu, perbandingan performa yang bermakna secara metodologis pada penelitian ini adalah perbandingan MASE antar metode pada data uji yang identik (lihat kriteria kelayakan relatif pada Subbab 3.2.9.1), bukan ambang mutlak $MASE < 1$. Visualisasi perbandingan nominal pendapatan aktual terhadap nilai

prediksi dari model LSTM Hybrid disajikan pada Gambar 4.18.



Gambar 4.18 Grafik Pendapatan Aktual vs. Prediksi Model LSTM Hybrid

4.4.2 Evaluasi Multi-Seed dan Analisis Kestabilan

Meningkatnya sensitivitas performa model LSTM terhadap inisialisasi bobot acak awal pada data kecil mengharuskan pengujian dilakukan menggunakan pendekatan *multi-seed evaluation* dengan melatih model sebanyak sepuluh kali menggunakan nilai *seed* acak yang berbeda. Prosedur pengujian diimplementasikan sebagai perulangan pelatihan dengan pengaturan *seed* eksplisit pada seluruh sumber keacakan (Python, NumPy, dan TensorFlow) sebagaimana disajikan pada Kode Program IV.7. Ringkasan statistik hasil pengujian sepuluh *seeds* tersebut disajikan pada Tabel 4.4.

```
1 def set_seed(s):
```

```

2     os.environ['PYTHONHASHSEED'] = str(s)
3     random.seed(s); np.random.seed(s); tf.random.set_seed(s)
4
5     rows = []
6     for s in range(N_SEEDS):    # N_SEEDS = 10
7         set_seed(s)
8         cb = [EarlyStopping('val_loss', patience=20,
9                             restore_best_weights=True, verbose=0),
10              ReduceLROnPlateau('val_loss', factor=0.5,
11                                patience=8, min_lr=1e-6,
12                                verbose=0)]
13
14         mdl = build()
15         mdl.fit(X_tr, y_tr, validation_data=(X_va, y_va),
16               epochs=200, batch_size=16, callbacks=cb, verbose=0)
17         # Rekonstruksi log-return prediksi ke nominal Rupiah
18         logret_hat = inv_logret(
19             mdl.predict(X_te, verbose=0).flatten())
20         y_lstm = np.expml(np.loglp(rev_prev) + logret_hat)
21         r = metrics(rev_true, y_lstm); r['seed'] = s
22         rows.append(r)
23
24     res = pd.DataFrame(rows)    # rata-rata +- deviasi per metrik

```

Kode Program IV.7: Prosedur Evaluasi *Multi-Seed* (10 Kali Pelatihan Ulang)

Tabel 4.4 Statistik Performa LSTM Hybrid pada 10 Seed

Metrik	Rata-rata $\pm$ Simpangan baku	Rentang (min – maks)
MAE (Rp)	667.718 $\pm$ 145.024	495.527 – 1.048.967
RMSE (Rp)	897.563 $\pm$ 165.804	703.721 – 1.320.587
sMAPE	38,06% $\pm$ 3,96%	29,16% – 44,63%
MASE	1,840 $\pm$ 0,400	1,365 – 2,891

Hasil pada Tabel 4.4 menunjukkan nilai simpangan baku (*standard deviation*) yang cukup signifikan (MAE $\pm$ Rp 145.024,00 dan MASE $\pm$ 0,400). Hal ini membuktikan adanya ketidakstabilan performa model LSTM yang disebabkan oleh ukuran data yang terbatas, performa model sangat bergantung pada keberuntungan inisialisasi parameter awal. Selain itu, sebaran data menunjukkan bahwa hanya terdapat 1 dari 10 percobaan (10%) yang berhasil mengungguli performa model pembandingan *Naive* dan *SARIMA*, yaitu pada *seed* ke-7 dengan MAE sebesar Rp 495.527,00. Oleh karena itu, pelaporan kinerja model LSTM berdasarkan uji coba tunggal (*single run*) berisiko memberikan kesimpulan yang kurang valid atau menyesatkan. Distribusi nilai MAE dari sepuluh *seeds* tersebut divisualisasikan dalam bentuk *boxplot* pada Gambar 4.19.



Gambar 4.19 Boxplot Distribusi MAE Hasil Pengujian *Multi-Seed*

4.4.3 Evaluasi Augmentasi Data Sintetis TimeGAN

Sebagai upaya mitigasi terhadap keterbatasan ukuran dataset yang menjadi akar penyebab ketidakstabilan model LSTM, hasil implementasi augmentasi data sintetis TimeGAN (lihat Subbab 4.3.3) dievaluasi dengan membandingkan performa model LSTM multi-langkah (*look-back* 14 hari aktif, horizon 7 hari) yang dilatih dalam dua kondisi: hanya menggunakan 199 sekuens data riil (*baseline real-only*), dan menggunakan gabungan data riil dengan 298 sekuens sintetis (rasio augmentasi 1,5). Hasil perbandingan pada data uji disajikan pada Tabel 4.5.

Tabel 4.5 Perbandingan Performa Eksperimen Augmentasi TimeGAN (*Multi-Step*, Horizon 7)

Model	MAE (Rp)	RMSE (Rp)	sMAPE	MASE
Seasonal-Naive ($k = 5$)	755.403	975.130	37,58%	2,082
Seasonal-Naive ($k = 7$)	783.179	985.180	38,24%	2,158
LSTM + Augmentasi TimeGAN	860.695	1.047.842	41,49%	2,372
LSTM Tanpa Augmentasi	1.750.355	1.935.119	115,40%	4,823

Perlu dicatat bahwa nilai galat pada Tabel 4.5 tidak dapat dibandingkan secara langsung dengan Tabel 4.3, karena eksperimen augmentasi ini menggunakan skema prediksi multi-langkah langsung (*direct multi-step*, horizon 7 hari sekaligus) yang secara inheren lebih sulit daripada skema satu langkah ke depan (*one-step-ahead*).

Hasil eksperimen menunjukkan dua temuan penting. Pertama, augmentasi TimeGAN terbukti efektif memperbaiki kualitas pelatihan LSTM pada data terbatas: nilai MAE model turun drastis dari Rp 1.750.355,00 menjadi Rp 860.695,00 (perbaikan sekitar 50,8%), dan nilai MASE membaik dari 4,823 menjadi 2,372. Kedua, meskipun mengalami perbaikan signifikan, model LSTM teraugmentasi tetap belum mampu mengungguli *baseline Seasonal-Naive* ($k = 5$, MAE Rp 755.403,00) yang memanfaatkan pola musiman mingguan secara sederhana. Perlu dicatat bahwa evaluasi multi-langkah ini menguji *Seasonal-Naive* pada konfigurasi $k = 5$ dan $k = 7$, sedangkan layanan produksi memakai $k = 4$ sebagai kompromi responsivitas–stabilitas. Ketiganya menunjukkan karakteristik performa yang serupa karena sama-sama merata-ratakan beberapa kemunculan terakhir hari sejenis. Temuan ini memperkuat kesimpulan sebelumnya bahwa pada volume data saat ini, metode statistik musiman sederhana masih menjadi pilihan

paling andal untuk disajikan kepada pengguna, sekaligus menunjukkan bahwa augmentasi data sintetis merupakan arah yang menjanjikan apabila dikombinasikan dengan data riil yang lebih panjang di masa mendatang.

4.5 Hasil Pengujian Sistem

Pengujian sistem dilakukan untuk memvalidasi fungsionalitas aplikasi dan memeriksa kebenaran logika internal komponen kritis pada layanan API prediksi yang telah diintegrasikan. Pengujian mencakup uji coba fungsional *Black Box*, uji telusur logika kode *White Box*, serta rekapitulasi evaluasi kinerja model prediksi yang telah dibahas pada Subbab 4.4.

4.5.1 Skenario Pengujian

Rancangan skenario pengujian fungsional *black box* disusun untuk 14 kasus penggunaan utama yang melibatkan peran Owner dan Kasir, sebagaimana telah dijabarkan pada Tabel 3.11 (Bab III), meliputi antara lain registrasi toko, autentikasi pengguna, pengelolaan produk dan kategori, proses *checkout* transaksi, pencetakan struk, sinkronisasi *offline-first*, serta dasbor laporan analitik. Skenario pengujian *white box* disusun secara terpisah dengan menelusuri jalur logika kode pada tiga fungsi kritis di layanan API prediksi, yaitu fungsi *Seasonal-Naive* (*by_dow*), fungsi metrik evaluasi sMAPE dan MASE, serta fungsi prediksi rekursif (*forecast_hybrid_stable*), sebagaimana telah dirancang pada Subbab 3.2.9.3. Kedua rancangan pengujian ini bersifat saling melengkapi: pengujian *black box* memvalidasi kesesuaian antara masukan dan keluaran pada level antarmuka

pengguna, sedangkan pengujian *white box* memvalidasi kebenaran perhitungan pada level kode program.

4.5.2 Hasil Black Box Testing

Pengujian fungsionalitas sistem menggunakan metode Black Box diterapkan pada 14 skenario kasus penggunaan utama yang melibatkan peran Owner dan Kasir.

Hasil pengujian diringkas pada Tabel 4.6.

Tabel 4.6 Hasil Pengujian Black Box

No.	Fitur / Skenario	Hasil yang Diharapkan	Hasil Riil	Status
1	Registrasi Toko	Akun owner baru dan data toko berhasil didaftarkan di cloud database.	Sesuai Harapan	Berhasil
2	Login Pengguna	Masuk ke dasbor utama sesuai hak akses peran (Owner/Kasir).	Sesuai Harapan	Berhasil
3	Checkout Belanja	Transaksi tersimpan, stok barang berkurang otomatis di lokal.	Sesuai Harapan	Berhasil
4	Terapkan Diskon	Total belanja terpotong sesuai nilai nominal diskon/voucher.	Sesuai Harapan	Berhasil
5	Cetak Struk Fisik	Printer thermal mencetak detail nota transaksi via Bluetooth.	Sesuai Harapan	Berhasil
6	Kelola Produk	Menambah, mengedit, dan menghapus katalog produk di basis data.	Sesuai Harapan	Berhasil
7	Kelola Kategori	Mengatur kategori produk untuk pengelompokan menu kasir.	Sesuai Harapan	Berhasil
8	Audit Mutasi Stok	Riwayat keluar masuk barang tercatat di log stock_history.	Sesuai Harapan	Berhasil

No.	Fitur / Skenario	Hasil yang Diharapkan	Hasil Riil	Status
9	Dasbor Ringkasan	Menampilkan ringkasan omzet dan grafik penjualan aktual.	Sesuai Harapan	Berhasil
10	Smart Analytics	Grafik prediksi LSTM untuk 7 hari ke depan dapat ditampilkan.	Sesuai Harapan	Berhasil
11	Broadcast Notif	Pengiriman notifikasi broadcast dari owner muncul di layar kasir.	Sesuai Harapan	Berhasil
12	Sinkronisasi Data	Data transaksi offline terunggah otomatis ke cloud saat online.	Sesuai Harapan	Berhasil
13	Kelola Staf Karyawan	Owner dapat menambah dan mengatur peran staf kasir.	Sesuai Harapan	Berhasil
14	Atur Profil Toko	Informasi nama, alamat, dan logo toko berhasil diubah.	Sesuai Harapan	Berhasil

Berdasarkan hasil uji coba pada Tabel 4.6, seluruh fungsi utama aplikasi POS mobile dan server-side API berjalan dengan status sukses ("Berhasil"), membuktikan kelayakan operasional sistem untuk penggunaan harian.

Sebagai bagian dari skenario #12 (Sinkronisasi Data), pengujian fitur *offline-first* dilakukan lebih rinci untuk memastikan keandalan penyimpanan lokal menggunakan Isar DB ketika koneksi internet terputus dan proses sinkronisasi otomatis ketika koneksi terhubung kembali. Rincian skenario pengujian sinkronisasi tersebut dijabarkan pada Tabel 4.7.

Tabel 4.7 Hasil Pengujian Mekanisme Sinkronisasi

No	Skenario Pengujian	Hasil Pengujian	Status
1	Melakukan transaksi checkout saat jaringan terputus (Luring).	Transaksi tersimpan di Isar DB lokal dengan status <i>is_synced = false</i> (penanda yang sama dinamai <i>isSynced</i> pada lapisan kode Dart, mengikuti konvensi penamaan masing-masing platform). Stok produk berkurang di lokal.	Berhasil
2	Membuka riwayat transaksi kasir saat luring.	Menampilkan daftar transaksi lokal secara instan tanpa memicu error atau halaman kosong.	Berhasil
3	Menghubungkan perangkat kembali ke internet (Daring).	Mesin <i>SyncNotifier</i> mendeteksi koneksi dan mengunggah data transaksi ke Supabase.	Berhasil
4	Memeriksa status database cloud setelah sinkronisasi.	Data transaksi masuk ke Supabase, dan status di lokal berubah menjadi <i>is_synced = true</i> .	Berhasil

Hasil uji coba membuktikan bahwa arsitektur offline-first menjamin operasional POS kasir tetap berjalan tanpa kendala saat konektivitas internet tidak stabil, serta menjaga konsistensi data transaksi saat online kembali.

4.5.3 Hasil White Box Testing

Pengujian *white box* dilakukan dengan menelusuri jalur logika (*code path*) dari tiga fungsi kritis pada layanan API prediksi menggunakan data masukan yang telah diketahui nilai keluarannya secara manual, kemudian membandingkan hasil

eksekusi aktual terhadap hasil kalkulasi *ground truth*. Ringkasan hasil penelusuran jalur logika disajikan pada Tabel 4.8.

Tabel 4.8 Hasil Pengujian White Box

No	Fungsi / Jalur Logika	Kondisi Uji	Hasil yang Diharapkan	Status
1	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tersedia $\geq k$ (jalur utama)	Nilai prediksi merupakan rata-rata k kemunculan terakhir hari kerja yang sama	Berhasil
2	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tersedia $< k$ (jalur cabang <i>partial</i>)	Nilai prediksi merupakan rata-rata dari seluruh data hari kerja yang tersedia	Berhasil
3	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tidak tersedia sama sekali (jalur <i>fallback</i>)	Nilai prediksi menggunakan rata-rata 10 hari aktif terakhir keseluruhan	Berhasil
4	<i>smape</i>	Nilai aktual dan prediksi sama-sama bernilai 0 (jalur penyebut nol)	Fungsi tidak menghasilkan galat pembagian dengan nol (<i>division by zero</i>)	Berhasil
5	<i>mase</i>	Galat naif <i>in-sample</i> bernilai positif normal (jalur utama)	Nilai MASE terhitung sesuai rasio MAE model terhadap MAE naif	Berhasil
6	<i>forecast_hybrid_stable</i>	Nilai <i>log-return</i> mentah melebihi persentil 90 data latih (jalur <i>clipping</i>)	Nilai <i>log-return</i> dipotong tepat pada batas atas persentil 90	Berhasil
7	<i>forecast_hybrid_stable</i>	Iterasi horizon ke- n dengan $n > 1$ (jalur <i>damping</i>)	Besaran perubahan <i>log-return</i> teredam sesuai faktor $\phi^{(n-1)}$	Berhasil
8	<i>forecast_hybrid_stable</i>	Nilai omzet hasil rekonstruksi melampaui nilai maksimum historis (jalur <i>safety rail</i>)	Nilai omzet dipotong tepat pada batas <i>REV_CEIL</i>	Berhasil

Berdasarkan hasil pada Tabel 4.8, seluruh jalur logika kritis pada ketiga fungsi yang diuji, yaitu perhitungan *Seasonal-Naive*, metrik evaluasi sMAPE/MASE, dan prediksi rekursif, telah tervalidasi menghasilkan keluaran yang sesuai dengan perhitungan manual, sehingga tidak ditemukan kesalahan logika (*logic error*) pada percabangan kode yang diuji.

4.5.4 Evaluasi Kinerja Model

Evaluasi kinerja model telah dipaparkan secara rinci pada Subbab 4.4.

4.6 Pembahasan

Bagian ini membahas temuan hasil implementasi, kontribusi fitur offline-first terhadap kelancaran operasional kasir, serta kemampuan analitik prediksi LSTM dalam meminimalkan masalah persediaan barang.

4.6.1 Pembahasan Pengujian Fungsional dan Arsitektur Offline-First

Hasil pengujian Black Box pada 14 skenario menunjukkan tingkat kesuksesan 100% ("Berhasil"). Integrasi antara basis data lokal Isar DB dan basis data cloud Supabase terbukti sangat andal. Melalui skema sinkronisasi yang dirancang, kasir tidak perlu bergantung pada koneksi internet saat menginput transaksi. Hal ini menghilangkan risiko terhambatnya antrean kasir akibat koneksi internet yang lambat atau terputus secara tiba-tiba.

Penggunaan local database Isar DB juga memberikan performa loading data yang sangat cepat. Secara observasi, operasi baca-tulis produk dan transaksi lokal

terasa hampir seketika (*near-instant*) dan jauh lebih responsif dibandingkan operasi yang bergantung pada pemanggilan REST API database cloud secara langsung, yang turut dipengaruhi oleh kondisi dan latensi jaringan. Hal ini meningkatkan efisiensi kerja kasir secara signifikan. Perlu dicatat bahwa perbandingan ini bersifat observasi kualitatif, bukan hasil pengukuran latensi terstruktur (mis. jumlah sampel, alat ukur, dan kondisi jaringan yang terkendali), sehingga angka waktu tempuh kuantitatif belum dapat dilaporkan pada penelitian ini.

4.6.2 Pembahasan Hasil Prediksi Penjualan LSTM

Secara keseluruhan, hasil pengujian menunjukkan bahwa pada dataset transaksi penjualan kantin EatsTEDI UGM dengan 313 hari aktif, model LSTM, termasuk varian hybrid residual yang merupakan konfigurasi terbaik, tidak mengungguli metode pembandingan sederhana (*Naive* dan *Mean-7*) maupun model statistik *SARIMA* secara rata-rata, dan hanya mampu kompetitif pada kasus terbaiknya (1 dari 10 percobaan *multi-seed*). Hasil evaluasi ini bukan merupakan suatu kegagalan atau anomali sistem, melainkan sejalan dengan temuan luas dalam berbagai literatur prediksi deret waktu komersial ritel (seperti pada kompetisi prediksi global M3 dan M4). Literatur tersebut membuktikan bahwa metode statistik klasik dan naif kerap mengungguli pendekatan pembelajaran mendalam (*deep learning*) ketika data historis yang tersedia relatif terbatas dan deret waktu didominasi secara kuat oleh komponen persistensi jangka pendek.

Dalam konteks operasional kantin kampus EatsTEDI UGM, dominasi

komponen persistensi ini sangat nyata karena nilai pendapatan harian sangat berkorelasi kuat dengan nilai pendapatan hari aktif sebelumnya. Pola ketergantungan jangka pendek ini ditangkap dengan sangat presisi oleh model *Naive* (kemarin) yang memiliki kesalahan MAE terendah sebesar Rp 519.841,00. Di sisi lain, model LSTM Hybrid yang memiliki kapasitas parameter lebih besar cenderung melakukan penghalusan nilai prediksi secara berlebihan (*over-smoothing*) pada data latih yang pendek, sehingga tidak mampu menangkap lonjakan-lonjakan ekstrem omzet harian yang dipicu oleh dinamika aktivitas mahasiswa di lapangan.

Sebagai upaya mengatasi akar permasalahan keterbatasan data tersebut, penelitian ini turut menguji peran augmentasi data sintetis menggunakan TimeGAN. Hasil eksperimen menunjukkan bahwa penambahan sekuens sintetis mampu memperbaiki kualitas pembelajaran model LSTM secara substansial (penurunan MAE sekitar 50,8% dibandingkan model tanpa augmentasi pada skema multi-langkah), yang menandakan bahwa kegagalan LSTM pada penelitian ini memang bersumber dari kelangkaan data, bukan dari kesalahan arsitektur semata. Namun demikian, model LSTM teraugmentasi tetap belum melampaui *baseline Seasonal-Naive*, sehingga augmentasi sintetis diposisikan sebagai pelengkap yang menjanjikan, bukan pengganti, dari akumulasi data transaksi riil jangka panjang.

Kontribusi ilmiah dari penelitian ini terletak pada ketelitian metodologis evaluasi model yang diterapkan, yaitu:

1. **Penggunaan Model Pembanding (*Baselines*) yang Tepat:** Menyandingkan model LSTM dengan metode naif, rata-rata bergerak, dan SARIMA untuk memvalidasi apakah penambahan kompleksitas komputasi model AI memberikan nilai tambah akurasi prediksi yang sepadan.
2. **Pemilihan Metrik Evaluasi yang Valid:** Menggunakan sMAPE dan MASE yang tahan terhadap pembagian bernilai nol atau sangat kecil pada hari-hari libur, menghindari kesalahan *exploding MAPE* yang menyesatkan.
3. **Pengujian Kestabilan melalui Multi-Seed:** Melaporkan sebaran nilai performa model dari sepuluh kali pelatihan secara acak, sehingga mengungkap ketidakstabilan model LSTM pada ukuran data yang kecil secara transparan.
4. **Eksplorasi Augmentasi Data Sintetis:** Menguji efektivitas TimeGAN sebagai strategi mitigasi keterbatasan data pada prediksi penjualan UMKM, lengkap dengan kuantifikasi perbaikan galat terhadap model tanpa augmentasi dan posisinya relatif terhadap *baseline* musiman.

Kerangka evaluasi ini menghasilkan kesimpulan analisis yang jujur, objektif, dan dapat dipertanggungjawabkan secara akademik, sekaligus memberikan rekomendasi praktis bagi pengelola bisnis: untuk skala volume data transaksi harian UMKM saat ini, metode *Naive*, *Seasonal-Naive*, atau *SARIMA* lebih direkomendasikan untuk diintegrasikan sebagai fitur visualisasi dasbor prediksi penjualan harian pada aplikasi POS, sedangkan penerapan algoritma LSTM baru relevan untuk ditinjau kembali di masa depan apabila volume data transaksi

historis telah bertambah secara signifikan (mencakup minimal 3–5 tahun operasional). Rekomendasi tersebut telah diimplementasikan secara nyata pada penelitian ini: layanan API prediksi produksi yang terhubung ke aplikasi POS menyajikan metode *Seasonal-Naive* ($k = 4$) untuk prediksi harian, *Mean-4* untuk mingguan, dan *Mean-3* untuk bulanan, sementara model LSTM beserta hasil eksperimen augmentasi TimeGAN didokumentasikan sebagai artefak riset yang siap diaktifkan kembali ketika data telah memadai.

4.7 Keterbatasan Sistem dan Penelitian

Meskipun sistem POS mobile dengan fitur prediksi penjualan harian ini telah berhasil diimplementasikan dan diuji, terdapat beberapa keterbatasan operasional maupun metodologi penelitian yang harus diperhatikan.

4.7.1 Keterbatasan Sistem POS

Beberapa keterbatasan operasional dari sistem POS mobile yang dikembangkan meliputi:

1. **Keterbatasan Cold Start pada Toko Baru:** Model prediksi LSTM memerlukan data transaksi historis runtun waktu yang kontinu. Sebagaimana dijelaskan pada Subbab 3.1.6, model secara teknis membutuhkan minimal 7 hari aktif transaksi (panjang *sequence LOOK_BACK*) agar dapat dijalankan sama sekali, namun hasil proyeksi baru dianggap cukup andal untuk ditampilkan tanpa peringatan *cold start* setelah data transaksi terkumpul minimal selama 30 hari sebagai periode pemanasan awal (*warm-up period*).

2. **Ketergantungan Data Terkini:** Meskipun operasional transaksi kasir dapat berjalan tanpa internet (offline), kualitas proyeksi modul prediksi LSTM bergantung pada kelengkapan data transaksi aktual yang menjadi *payload* permintaan analisis. Jika data transaksi terbaru belum tercatat atau tersinkronkan, akurasi hasil proyeksi prediksi untuk hari berikutnya dapat menurun karena tidak menangkap tren transaksi paling akhir.
3. **Ketergantungan Akses Server untuk Hasil Prediksi:** Karena keterbatasan sumber daya komputasi dan konsumsi baterai perangkat mobile, proses kalkulasi prediksi model LSTM yang berat dialihkan sepenuhnya ke layanan inferensi Python yang di-*hosting* pada platform Hugging Face. Akibatnya, meskipun kasir dapat bertransaksi secara offline, pengguna tetap memerlukan koneksi internet aktif untuk memperbarui visualisasi prediksi analitik terbaru dari API inferensi ke dasbor aplikasi. Selain itu, layanan inferensi gratis pada Hugging Face dapat mengalami kondisi *cold start* (jeda pemuatan saat *server* baru aktif kembali dari *idle*) yang memperlambat respons analisis pertama.

4.7.2 Keterbatasan Penelitian Model Prediksi

Keterbatasan utama dalam pemodelan prediksi pada penelitian ini meliputi:

1. **Keterbatasan Volume Dataset:** Jumlah data transaksi aktif riil dari platform EatsTEDI UGM relatif sedikit untuk standar pemodelan pembelajaran mendalam (*deep learning*), yakni hanya 313 hari aktif yang menyusut menjadi sekitar 212 sampel latih setelah pembentukan *sequence*.

Keterbatasan ini berdampak langsung pada tingginya sensitivitas model terhadap inisialisasi bobot acak awal (*seed variance*) yang memicu ketidakstabilan akurasi model.

2. **Keterbatasan Pengamatan Pola Musiman Jangka Panjang:** Rentang waktu transaksi yang kurang dari dua tahun belum memungkinkan model LSTM untuk mempelajari pola musiman tahunan (*annual seasonality*) secara utuh dan komprehensif.
3. **Deret Waktu yang Terputus-putus:** Banyaknya hari non-aktif transaksi akibat libur kalender akademik kampus (seperti sepanjang bulan Januari dan Juli) serta akhir pekan menyebabkan deret waktu menjadi patah dan terputus-putus, yang menyulitkan jaringan saraf dalam mempelajari dependensi keterkaitan temporal jangka panjang secara kontinu.
4. **Bias Penyaringan Hari Aktif ($\text{revenue} > 0$):** Penyaringan data pada tahap *preprocessing* hanya mempertahankan hari kerja yang memiliki pendapatan positif ($\text{revenue} > 0$), sebagaimana dijelaskan pada Subbab 3.1.7. Konsekuensinya, hari kerja aktif dengan penjualan nol yang sebenarnya nyata turut terbuang dari dataset, bukan hanya akhir pekan atau libur kalender akademik. Akibat lanjutannya, deret *log-return* r_t yang menjadi target model dihitung antar hari aktif berurutan yang jarak kalender riilnya tidak seragam – dapat berupa 1 hari, namun juga dapat mencapai lebih dari 10 hari setelah masa libur panjang. Ketidakteraturan interval waktu ini melanggar sebagian asumsi keteraturan deret waktu (*regular*

time-series) yang mendasari arsitektur LSTM, dan diduga turut menjadi salah satu faktor yang memperberat kesulitan model dalam mempelajari pola dependensi temporal secara konsisten.

BAB V

PENUTUP

Bab ini menyajikan kesimpulan dari hasil perancangan, implementasi, dan pengujian sistem Point of Sale (POS) mobile dengan fitur prediksi penjualan harian menggunakan metode Long Short-Term Memory (LSTM) dan arsitektur offline-first, serta saran-saran untuk pengembangan sistem lebih lanjut di masa mendatang.

5.1 Kesimpulan

Berdasarkan hasil analisis, perancangan, implementasi, dan pengujian yang telah dilakukan pada penelitian ini, maka dapat ditarik beberapa kesimpulan sebagai berikut:

1. Penelitian ini telah berhasil membangun aplikasi *Point of Sale (POS) mobile* berbasis Flutter yang terintegrasi dengan basis data cloud Supabase PostgreSQL dan layanan API prediksi penjualan harian berbasis Python dan Flask. Modul riset LSTM berbasis TensorFlow/Keras dikembangkan dan didokumentasikan secara lengkap sebagai artefak penelitian, sedangkan layanan API produksi yang benar-benar dipanggil aplikasi menyajikan metode *Seasonal-Naive* berdasarkan hasil evaluasi komparatif, melalui arsitektur *prediction service* yang bersifat *model-agnostic* dan siap menyajikan model `.keras` begitu data mencukupi.
2. Penerapan arsitektur *offline-first* menggunakan basis data lokal Isar DB terbukti handal dalam menjaga keberlangsungan transaksi kasir tanpa

ketergantungan penuh pada koneksi internet. Secara observasi, operasi baca-tulis lokal terasa jauh lebih responsif dibandingkan operasi yang bergantung pada jaringan (belum diukur secara kuantitatif dan terstruktur), dan sinkronisasi otomatis menggunakan modul *SyncNotifier* berhasil mengunggah data transaksi lokal ke database cloud saat perangkat terhubung kembali ke internet.

3. Implementasi metode prediksi *Long Short-Term Memory* (LSTM) dengan pendekatan *hybrid residual* (memprediksi *log-return*) pada dataset harian aktif menghasilkan rata-rata kesalahan prediksi (*multi-seed evaluation*) berupa MAE sebesar Rp 667.718,00 $\pm$ Rp 145.024,00, RMSE sebesar Rp 897.563,00 $\pm$ Rp 165.804,00, sMAPE sebesar 38,06% $\pm$ 3,96%, dan MASE sebesar 1,840 $\pm$ 0,400. Hasil ini menunjukkan bahwa model LSTM Hybrid yang dikembangkan belum mampu mengungguli metode pembandingan *Naive* (MAE Rp 519.841,00, MASE 1,432) dan *SARIMA* secara rata-rata, dikarenakan deret pendapatan yang pendek serta tingginya persistensi jangka pendek pada data penjualan kantin EatsTEDI UGM. Upaya augmentasi data sintetis menggunakan TimeGAN terbukti menurunkan galat model LSTM multi-langkah secara signifikan (MAE membaik dari Rp 1.750.355,00 menjadi Rp 860.695,00), namun tetap belum mengungguli *baseline Seasonal-Naive*, sehingga layanan API prediksi produksi menyajikan metode *Seasonal-Naive* sebagai metode penyaji utama.
4. Hasil pengujian fungsionalitas menggunakan metode *Black Box Testing*

terhadap 14 skenario kasus penggunaan utama yang melibatkan peran Owner dan Kasir berjalan dengan sukses tanpa kegagalan (tingkat keberhasilan 100%), menunjukkan sistem layak dioperasikan secara penuh pada unit usaha UMKM.

5.2 Saran

Berdasarkan keterbatasan sistem yang diidentifikasi selama proses pengembangan dan pengujian, berikut adalah beberapa saran konstruktif untuk pengembangan sistem lebih lanjut:

1. **Penerapan Metode Prediksi Hybrid:** Untuk meningkatkan akurasi proyeksi penjualan pada data yang memiliki volatilitas tinggi atau tren musiman yang sangat dinamis, disarankan untuk menggabungkan model LSTM dengan model *Gated Recurrent Unit* (GRU) atau model statistik klasik ARIMA menjadi model *hybrid* (seperti ARIMA-LSTM atau LSTM-GRU).
2. **Mengatasi Masalah Cold Start:** Untuk memfasilitasi toko baru yang belum memiliki riwayat transaksi selama 30 hari, disarankan mengimplementasikan teknik *transfer learning* atau melatih model *global* awal menggunakan data transaksi historis dari toko sejenis sebelum melatih model secara spesifik menggunakan data toko tersebut.
3. **Penguatan Keamanan Data Lokal:** Guna melindungi data transaksi sensitif pelaku UMKM yang disimpan secara lokal pada perangkat fisik,

disarankan untuk mengaktifkan fitur enkripsi basis data lokal pada Isar DB dengan menggunakan kunci enkripsi dinamis yang dikelola secara aman oleh perangkat.

4. **Penyediaan Skalabilitas Tinggi (High Availability):** Untuk menghadapi potensi ekspansi multi-outlet dengan ribuan kasir aktif, arsitektur modul AI berbasis Flask disarankan dimigrasikan ke infrastruktur cloud dengan konfigurasi *load balancer*, *Docker container clusters*, dan replikasi basis data Supabase PostgreSQL untuk meminimalisasi *single point of failure*.
5. **Notifikasi Multi-Kanal Otomatis:** Mengembangkan fitur integrasi notifikasi dengan layanan pihak ketiga seperti WhatsApp API atau SMS Gateway untuk mengirimkan laporan ringkasan omzet harian secara langsung ke nomor WhatsApp Owner, serta memberikan peringatan dini jika terdapat stok produk tertentu yang berada di bawah ambang batas minimum (*safety stock*).
6. **Integrasi Sistem Pembayaran Digital (E-Wallet & QRIS Dynamic):** Menambahkan integrasi langsung dengan penyedia gerbang pembayaran (*payment gateway*) lokal untuk menghasilkan kode QRIS dinamis secara real-time pada layar transaksi kasir, sehingga mempermudah pembukuan dan meminimalkan kesalahan input nominal transaksi nontunai oleh kasir.
7. **Penambahan Fitur `gap_days` pada Variabel Masukan Model:** Untuk mengurangi dampak ketidakseragaman interval waktu antar hari aktif akibat penyaringan `revenue > 0` (lihat Subbab 4.7.2), disarankan menyertakan

fitur `gap_days` (jarak hari kalender terhadap hari aktif sebelumnya) sebagai variabel masukan tambahan pada model prediksi, sehingga model dapat mempelajari secara eksplisit pengaruh jeda waktu antar observasi terhadap besaran perubahan pendapatan.

DAFTAR PUSTAKA

- [1] A. Setiawan and B. T. Nugroho, “Development of Cross-Platform Point of Sale Application using Flutter Framework for Small and Medium Enterprises,” *International Journal of Advanced Computer Science and Applications*, vol. 14, no. 5, pp. 320–329, 2023.
- [2] R. Pratama and S. Handayani, “Digital Transformation of Indonesian SMEs: Implementation of Smart Point of Sales Systems,” *Jurnal Sistem Informasi (JSI)*, vol. 21, no. 1, pp. 12–25, 2025.
- [3] T. Brown and M. Green, “Demand Forecasting for Inventory Management in Small Retail Stores Using Neural Networks,” *Journal of Retailing and Consumer Services*, vol. 58, pp. 102–115, 2021.
- [4] S. Abbas, M. A. Khan, and A. Tariq, “Sales Forecasting Using Long Short-Term Memory (LSTM) Networks in Retail Industry,” *IEEE Access*, vol. 9, pp. 30900–30912, 2021.
- [5] E. Wilson and M. Davies, “Application of LSTM Networks to Solve Long-Term Memory Retention in Highly Seasonal Sales Data,” *Neural Networks*, vol. 148, pp. 45–56, 2022.
- [6] H. Choi and J. Lee, “Multivariate Time-Series Forecasting for Retail Sales Using LSTM with Economic Indicators,” *International Journal of Forecasting*, vol. 38, no. 3, pp. 890–905, 2022.
- [7] J. Martinez and R. Silva, “Architecture Design of Offline-First Mobile Application using Local Embedded Database and Remote Sync Server,” *IEEE Transactions on Software Engineering*, vol. 48, no. 8, pp. 2840–2852, 2022.
- [8] A. Novikov and I. Petrov, “Performance Comparison of Local NoSQL Embedded Databases in Flutter Framework: Hive, ObjectBox, and Isar,” *Communications in Computer and Information Science*, vol. 1780, pp. 112–126, 2023.
- [9] M. Fischer and L. Weber, “Evaluating Open-Source Backend-as-a-Service (BaaS) Platforms: A Case Study on Supabase and PostgreSQL,” *International Journal of Computer Science & Information Technology*, vol. 16, no. 1, pp. 45–58, 2024.
- [10] P. Kumar and R. Sharma, “Integrating Predictive Machine Learning Models into Enterprise Resource Planning and Point of Sales Systems,” *Journal of Systems and Software*, vol. 195, pp. 111–125, 2023.
- [11] H. Nguyen and V. Tran, “Decoupling Core Transact Systems and Analytical Machine Learning Frameworks inside Microservice Architectures,”

Journal of Systems Architecture, vol. 134, pp. 102–118, 2023.

- [12] D. Roberts and K. Thomas, “Designing Smart Mobile Applications with Server-Side Artificial Intelligence Models via RESTful Web Services,” *International Journal of Mobile Computing and Multimedia Communications*, vol. 13, no. 2, pp. 1–18, 2024.
- [13] Y. Zhang and X. Liu, “Comparative Analysis of LSTM and GRU for Time-Series Sales Forecasting,” *Applied Soft Computing*, vol. 115, pp. 108–122, 2022.
- [14] J. Heizer, B. Render, and C. Munson, *Operations Management: Sustainability and Supply Chain Management*, 12th ed. Boston, MA, USA: Pearson, 2017.
- [15] G. Thompson, “A Review of Evaluation Metrics for Time-Series Forecasting in Commercial Retail,” *Journal of Business Forecasting*, vol. 40, no. 2, pp. 75–88, 2021.
- [16] R. J. Hyndman and A. B. Koehler, “Another Look at Measures of Forecast Accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006.
- [17] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [18] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proc. 3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, USA, 2015.
- [19] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [20] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021.
- [21] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.
- [22] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “Statistical and Machine Learning Forecasting Methods: Concerns and Ways Forward,” *PLoS ONE*, vol. 13, no. 3, e0194889, 2018.
- [23] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “The M4 Competition: 100,000 Time Series and 61 Forecasting Methods,” *International Journal of Forecasting*, vol. 36, no. 1, pp. 54–74, 2020.

- [24] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative Adversarial Nets,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, pp. 2672–2680, 2014.
- [25] J. Yoon, D. Jarrett, and M. van der Schaar, “Time-series Generative Adversarial Networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 5508–5518, 2019.
- [26] L. White and J. Black, “Privacy-Preserving Machine Learning for Small Business Analytics: Scrubbing Personal Identifiable Information,” *Security and Privacy in Communication Networks*, vol. 512, pp. 200–215, 2025.
- [27] M. Abadi et al., “TensorFlow: A System for Large-Scale Machine Learning,” in *Proc. 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, Savannah, GA, USA, pp. 265–283, 2016.
- [28] A. Paszke et al., “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 8024–8035, 2019.
- [29] M. Grinberg, *Flask Web Development: Developing Web Applications with Python*, 2nd ed. Sebastopol, CA, USA: O’Reilly Media, 2018.
- [30] R. T. Fielding, “Architectural Styles and the Design of Network-based Software Architectures,” Ph.D. dissertation, University of California, Irvine, CA, USA, 2000.
- [31] L. Moroney, *The Definitive Guide to Firebase: Build Android Apps on Google’s Mobile Platform*. New York, NY, USA: Apress, 2017.
- [32] R. S. Pressman and B. R. Maxim, *Software Engineering: A Practitioner’s Approach*, 9th ed. New York, NY, USA: McGraw-Hill Education, 2020.
- [33] M. Poppendieck and T. Poppendieck, *Lean Software Development: An Agile Toolkit*. Boston, MA, USA: Addison-Wesley, 2003.
- [34] G. Booch, J. Rumbaugh, and I. Jacobson, *The Unified Modeling Language User Guide*, 2nd ed. Boston, MA, USA: Addison-Wesley, 2005.
- [35] P. P.-S. Chen, “The Entity-Relationship Model—Toward a Unified View of Data,” *ACM Transactions on Database Systems*, vol. 1, no. 1, pp. 9–36, 1976.

LAMPIRAN

LEMBAR KONSULTASI PEMBIMBING I
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Muhammad Kholis
NIM : 2022573010098
Judul TA : Rancang Bangun Aplikasi *Point of Sale* dengan
Fitur Prediksi Penjualan Harian Menggunakan
Metode *Long Short-Term Memory* (LSTM)
Pembimbing I : Zulfan Khairil Simbolon, S.T., M.Eng.
NIP : 196909021993031004

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing

LEMBAR KONSULTASI PEMBIMBING II
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Muhammad Kholis
NIM : 2022573010098
Judul TA : Rancang Bangun Aplikasi *Point of Sale* dengan
Fitur Prediksi Penjualan Harian Menggunakan
Metode *Long Short-Term Memory* (LSTM)
Pembimbing II : Azhar, S.T., M.T.
NIP : 196408301990031005

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing